



# 深度学习平台与应用

## 第二讲：线性分类器

范琦

[fanqi@nju.edu.cn](mailto:fanqi@nju.edu.cn)

2024年9月11日

- 课后作业: 20%
- 课程项目: 30%
- 期末考试: 50%

# 大 纲

- 图像分类
- K-NN 最近邻分类器
- 线性分类器

## ■ 图像分类是最核心的计算机视觉任务

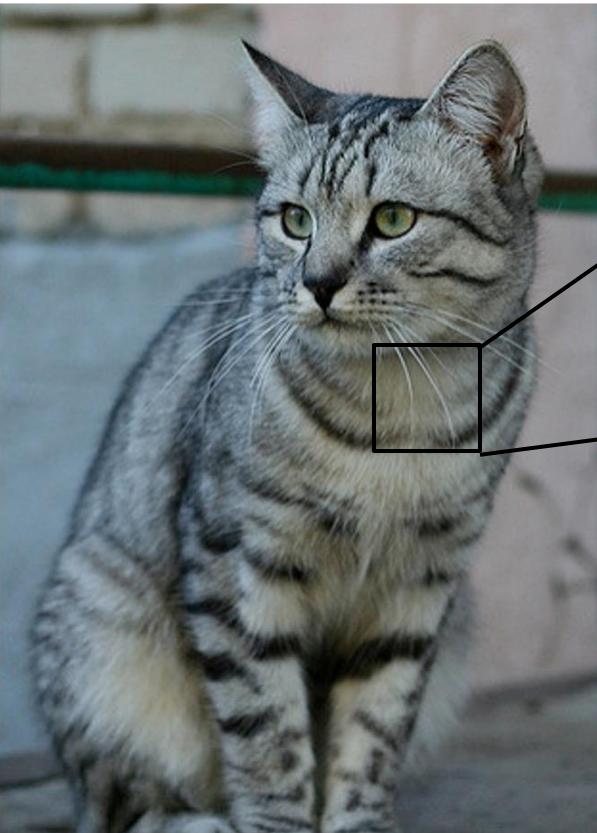


假设有一个标签集合  
{人, 狗, 猫, 汽车, ...}

模型的分类预测

猫

## ■ 问题：语义鸿沟（Semantic Gap）

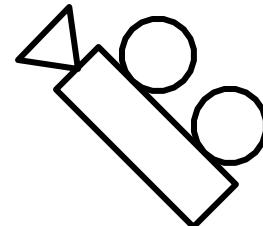
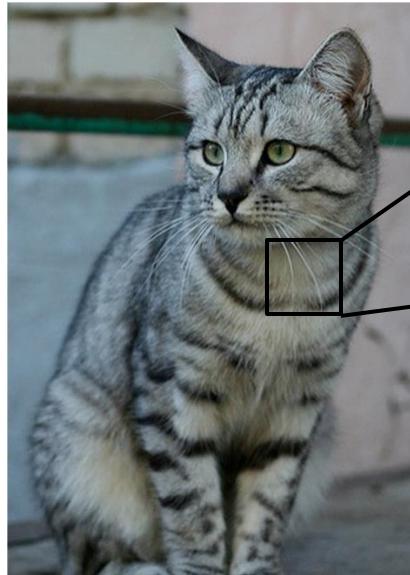
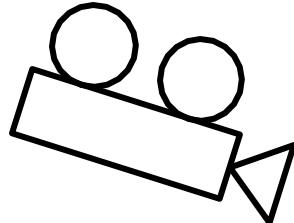


人眼看到的内容：  
**一只猫的图像**

[105 112 108 111 104 99 106 99 96 103 112 119 104 97 93 87]
[ 91 98 102 106 104 79 98 103 99 105 123 136 110 105 94 85]
[ 76 85 90 105 128 105 87 96 95 99 115 112 106 103 99 85]
[ 99 81 81 93 120 131 127 100 95 98 102 99 96 93 101 94]
[106 91 61 64 69 91 88 85 101 107 109 98 75 84 96 95]
[114 108 85 55 55 69 64 54 64 87 112 129 98 74 84 91]
[133 137 147 103 65 81 80 65 52 54 74 84 102 93 85 82]
[128 137 144 140 109 95 86 70 62 65 63 63 60 73 86 101]
[125 133 148 137 119 121 117 94 65 79 80 65 54 64 72 98]
[127 125 131 147 133 127 126 131 111 96 89 75 61 64 72 84]
[115 114 109 123 150 148 131 118 113 109 100 92 74 65 72 78]
[ 89 93 90 97 108 147 131 118 113 114 113 109 106 95 77 80]
[ 63 77 86 81 77 79 102 123 117 115 117 125 130 115 87]
[ 62 65 82 89 78 71 80 101 124 126 119 101 107 114 131 119]
[ 63 65 75 88 89 71 62 81 120 138 135 105 81 98 110 118]
[ 87 65 71 87 106 95 69 45 76 130 126 107 92 94 105 112]
[118 97 82 86 117 123 116 66 41 51 95 93 89 95 102 107]
[164 146 112 80 82 120 124 104 76 48 45 66 88 101 102 109]
[157 170 157 120 93 86 114 132 112 97 69 55 70 82 99 94]
[130 128 134 161 139 100 109 118 121 134 114 87 65 53 69 86]
[128 112 96 117 150 144 120 115 104 107 102 93 87 81 72 79]
[123 107 96 86 83 112 153 149 122 109 104 75 80 107 112 99]
[122 121 102 80 82 86 94 117 145 148 153 102 58 78 92 107]
[122 164 148 103 71 56 78 83 93 103 119 139 102 61 69 84]]

计算机看到的内容：  
**0-255的整数组成的矩阵**  
例如，RGB图像会表示为  
**HxWx3的矩阵**

## ■ 挑战：视角差异 (Viewpoint Variation)

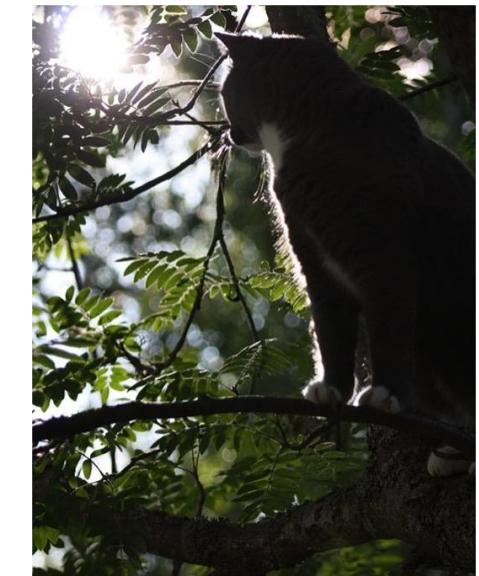


[105 112 108 111 184 99 106 99 96 103 112 119 184 97 93 87]
[ 91 98 102 186 184 79 99 103 89 105 128 136 119 185 84 85]
[ 76 85 89 105 128 105 87 96 95 99 115 112 106 103 99 85]
[ 99 81 81 93 128 131 127 100 95 98 102 99 96 93 101 84]
[106 91 61 64 69 91 88 85 101 107 109 98 75 84 96 85]
[114 100 85 55 55 69 64 54 65 52 54 74 81 102 93 74 84 81]
[133 137 147 103 56 81 80 65 52 54 74 81 102 93 74 85 82]
[134 137 144 140 109 95 86 70 62 65 63 68 60 73 86 101]
[125 133 149 137 119 121 117 94 65 79 80 65 54 64 72 89]
[127 125 131 147 133 127 126 131 111 96 89 75 61 64 72 84]
[115 114 109 123 158 148 131 119 113 109 100 92 74 65 72 70]
[ 89 93 90 97 100 147 131 118 113 114 113 109 106 95 77 80]
[ 63 77 86 81 77 79 102 123 117 115 117 125 125 130 115 87]
[ 62 65 82 89 78 71 80 101 124 126 119 101 107 114 131 119]
[ 65 65 75 88 89 71 62 81 120 138 135 105 81 98 110 118]
[ 87 65 71 77 87 106 95 69 45 76 130 126 107 92 94 105 112]
[118 97 82 86 117 123 116 66 41 51 95 93 89 95 102 107]
[164 146 112 80 82 120 124 104 76 49 45 66 88 101 102 109]
[157 170 157 120 93 96 114 132 112 97 69 55 70 82 99 64]
[130 120 134 161 139 100 109 118 121 134 114 87 65 53 69 86]
[128 112 96 117 158 144 120 115 104 107 102 93 87 81 72 79]
[123 107 96 86 83 112 153 149 122 109 104 75 80 107 112 99]
[122 121 102 80 82 86 94 117 145 148 153 102 58 78 92 107]
[122 164 148 103 71 56 78 83 93 103 119 139 102 61 69 84]



当相机视角改变时，  
所有像素都会变化

## ■ 挑战：光照变化 (Illumination)



当光照变化时，所有像素都会改变

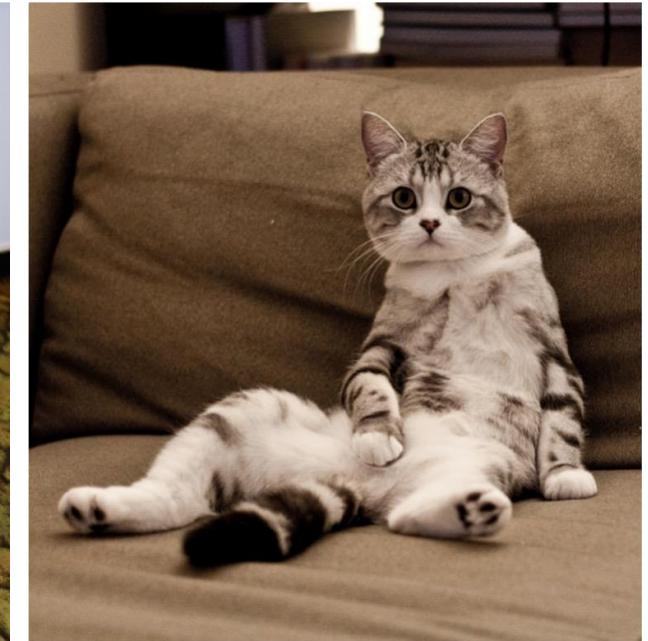
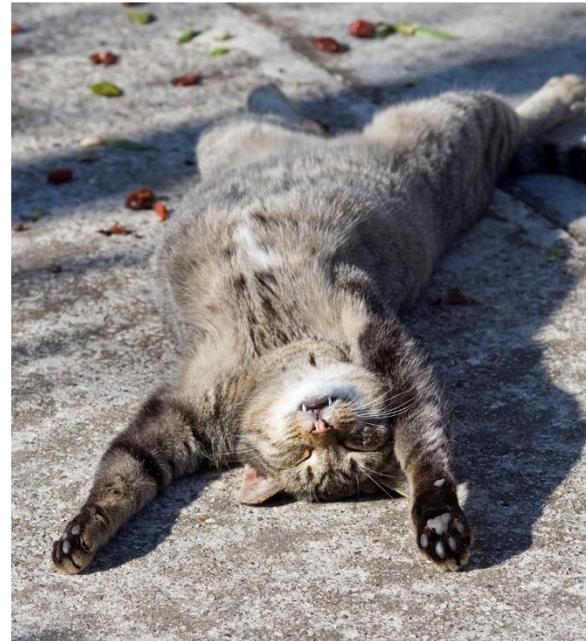
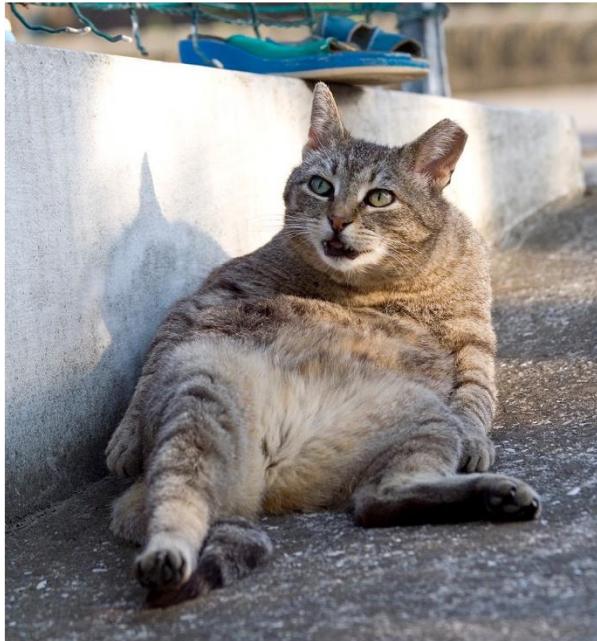
## ■ 挑战：杂乱的背景 (Background Clutter)



## ■ 挑战：遮挡 (Occlusion)



## ■ 挑战：形变 (Deformation)



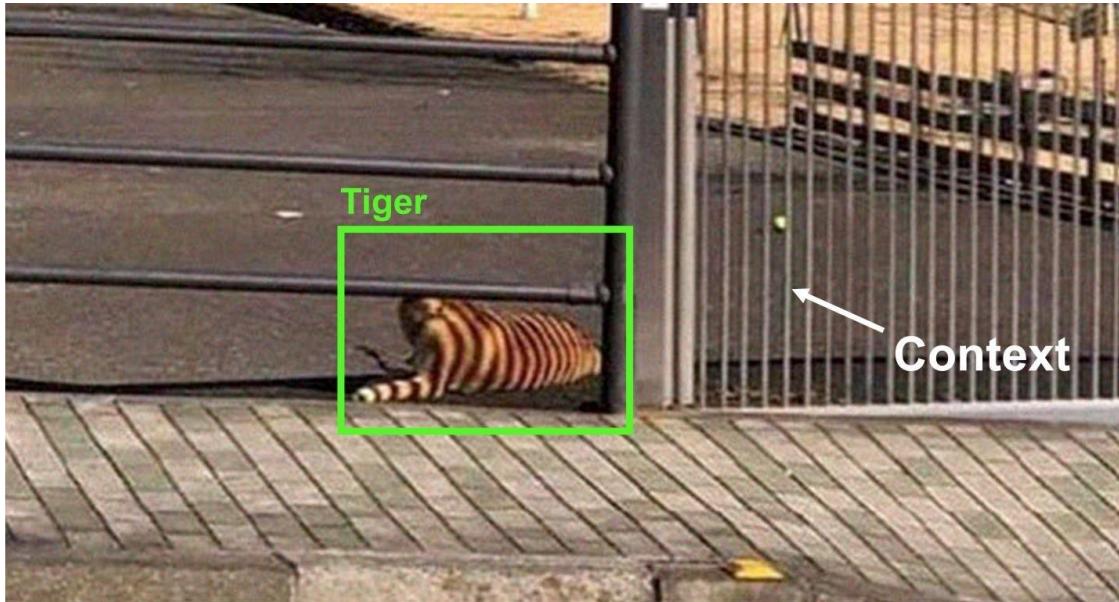
## ■ 挑战：类内差异 (Intra-Class Variation)



## ■ 挑战：类间相似 (Inter-Class Similarity)



## ■ 挑战：语义干扰 (Context Disturbance)



Skateboard



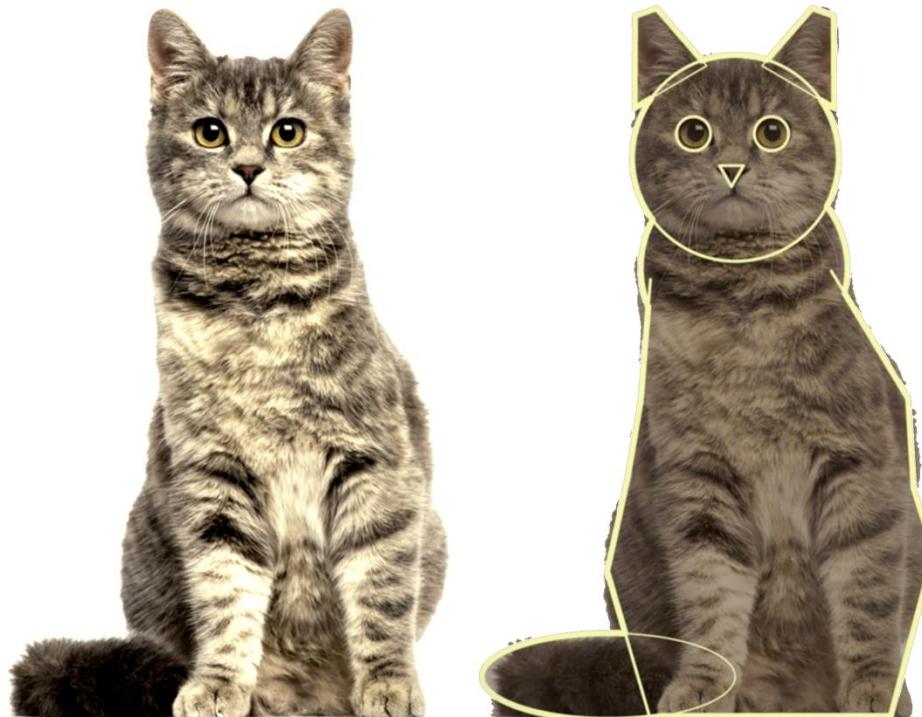
Snowboard



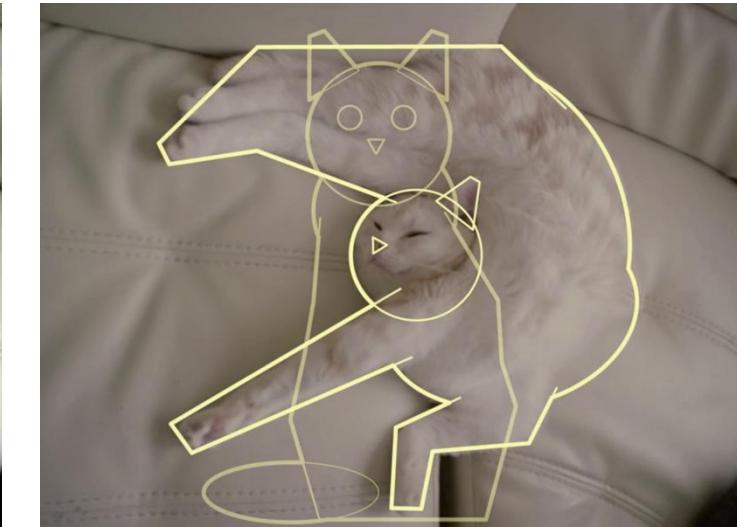
Microwave



## ■ 图像分类器 (Classifier)



与排序等算法不同，  
无法对图像识别算法进行硬编码



## ■ 基于规律的图像分类



找到边缘



统计规律

?

## ■ 数据驱动（Data-Driven）的图像分类

■ 收集图像和标签的数据集

■ 使用机器学习算法训练分类器

■ 使用分类器对新图像  
进行分类

airplane



automobile



bird



cat



deer



```
def train(images, labels):  
    # Machine learning!  
    return model
```

```
def predict(model, test_images):  
    # Use model to predict labels  
    return test_labels
```

# 大 纲

- 图像分类
- K-NN 最近邻分类器
- 线性分类器

## ■ 最近邻分类器

```
def train(images, labels):  
    # Machine learning!  
    return model
```



**记住所有数据和标签**

```
def predict(model, test_images):  
    # Use model to predict labels  
    return test_labels
```



**将测试图像预测为  
与其最相似的训练  
图像的标签**

## ■ 最近邻分类器

deer



bird



plane



cat



car



训练图像 + 图像标签



测试图像

距离度量



,



$\rightarrow \mathbb{R}$

## ■ 距离度量函数

L1 距离:

$$d_1(I_1, I_2) = \sum_p |I_1^p - I_2^p|$$

test image				training image				pixel-wise absolute value differences			
56	32	10	18	10	20	24	17	46	12	14	1
90	23	128	133	8	10	89	100	82	13	39	33
24	26	178	200	12	16	178	170	12	10	0	30
2	0	255	220	4	32	233	112	2	32	22	108

-                                   =    add → 456

# K-NN 最近邻分类器

```

import numpy as np

class NearestNeighbor:
    def __init__(self):
        pass

    def train(self, X, y):
        """ X is N x D where each row is an example. Y is 1-dimension of size N """
        # the nearest neighbor classifier simply remembers all the training data
        self.Xtr = X
        self.ytr = y

    def predict(self, X):
        """ X is N x D where each row is an example we wish to predict label for """
        num_test = X.shape[0]
        # lets make sure that the output type matches the input type
        Ypred = np.zeros(num_test, dtype = self.ytr.dtype)

        # loop over all test rows
        for i in xrange(num_test):
            # find the nearest training image to the i'th test image
            # using the L1 distance (sum of absolute value differences)
            distances = np.sum(np.abs(self.Xtr - X[i,:]), axis = 1)
            min_index = np.argmin(distances) # get the index with smallest distance
            Ypred[i] = self.ytr[min_index] # predict the label of the nearest example

        return Ypred
  
```

## 记忆训练数据

**对于每个测试数据：**

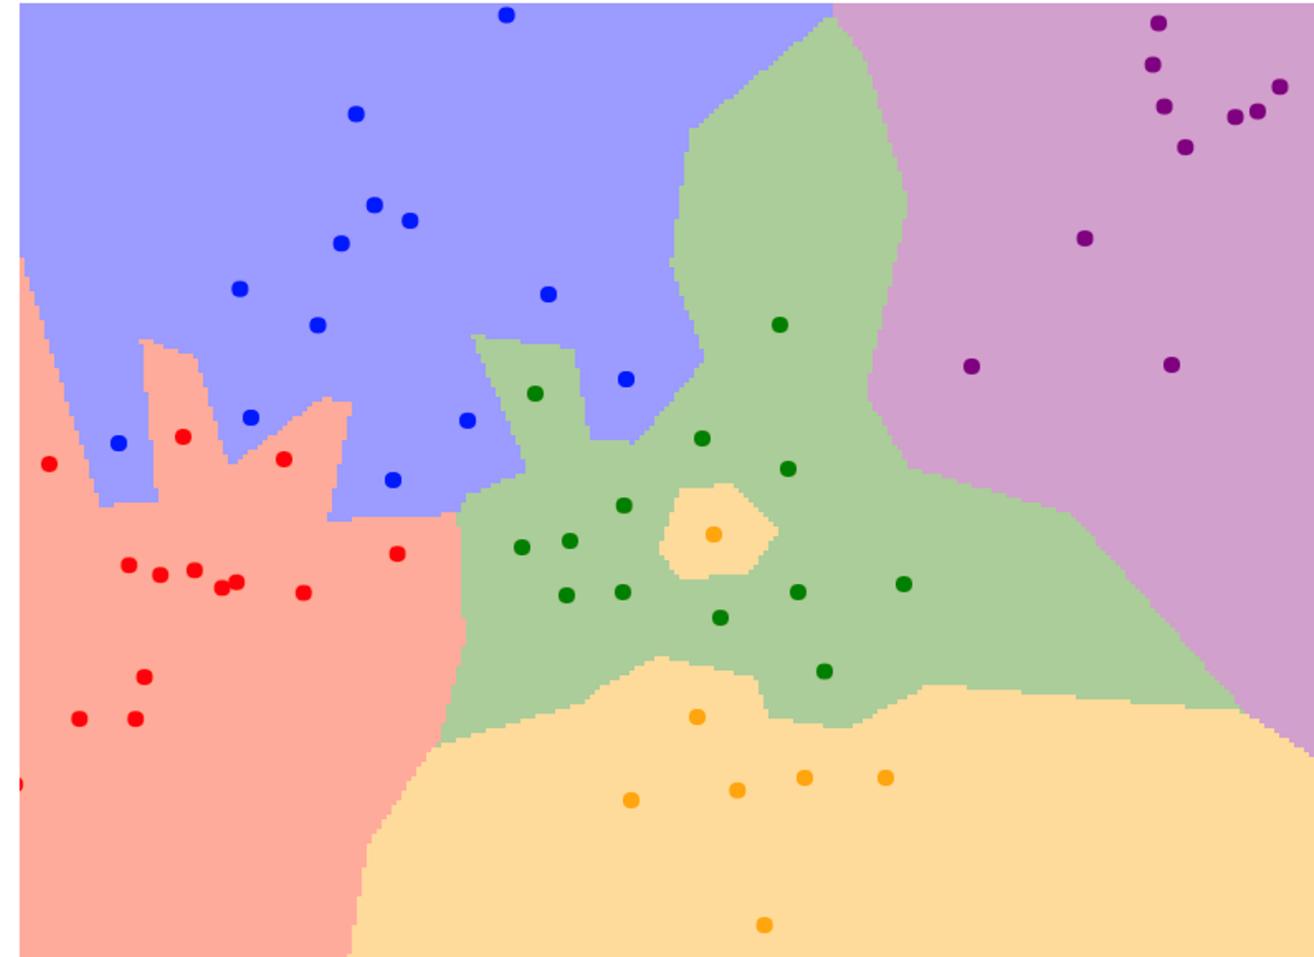
- 找到与其最相似的训练数据
- 将其预测为此训练数据的标签

**时间复杂度？**

- 1 近邻示例
- 存在的问题？

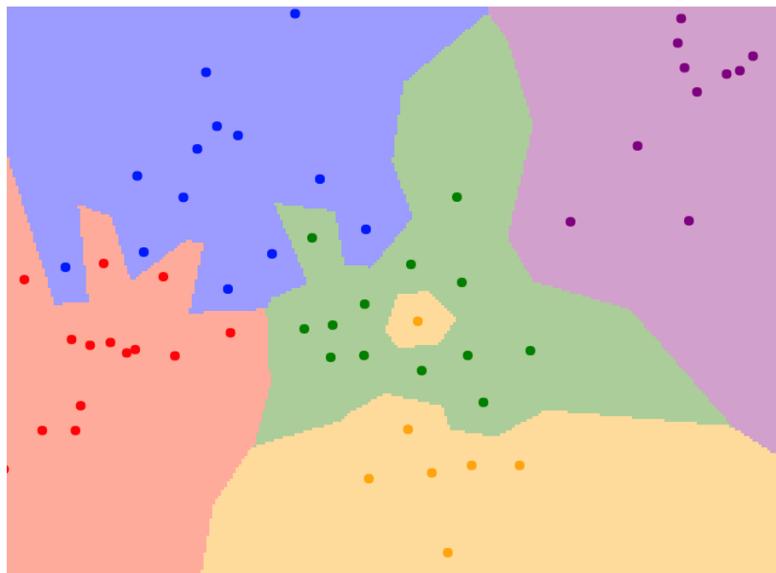
点：训练数据（2D）

区域：类别空间

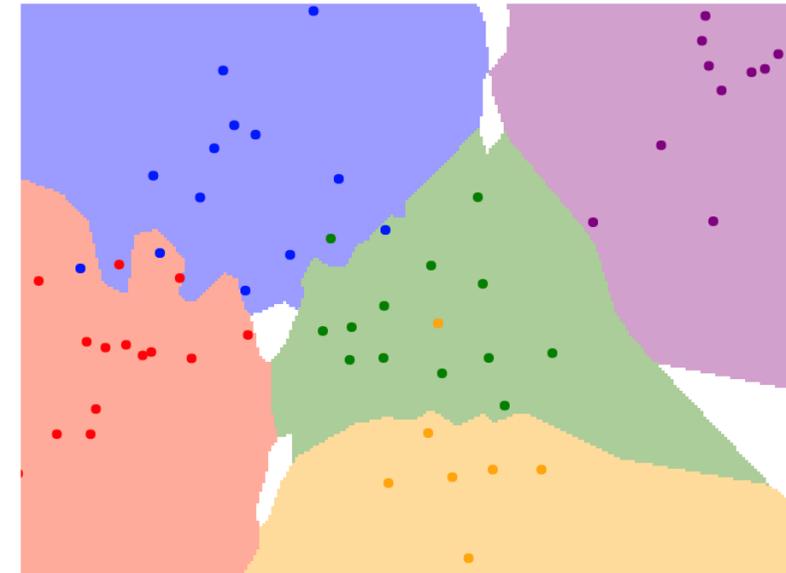


# K-NN 最近邻分类器

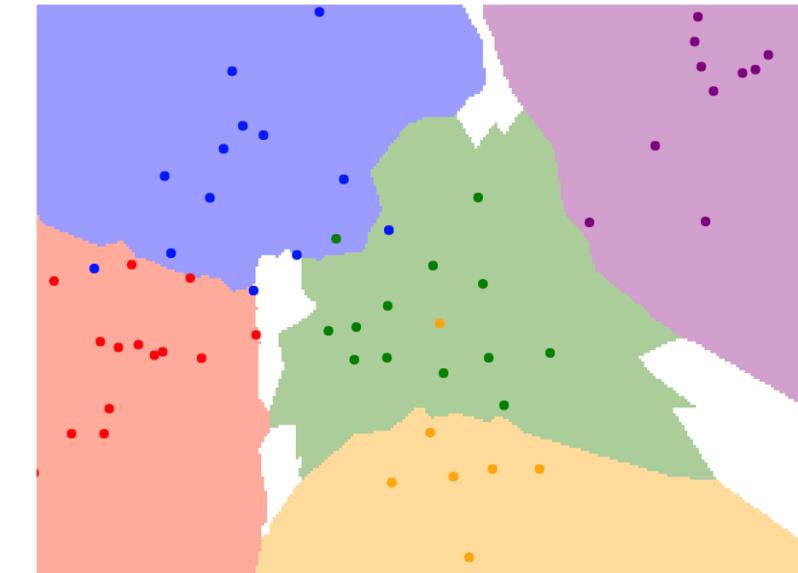
- K 近邻
- 问题：如果某个区域的 K 个最近邻是 K 个不同的类，怎么办？



K=1



K=3

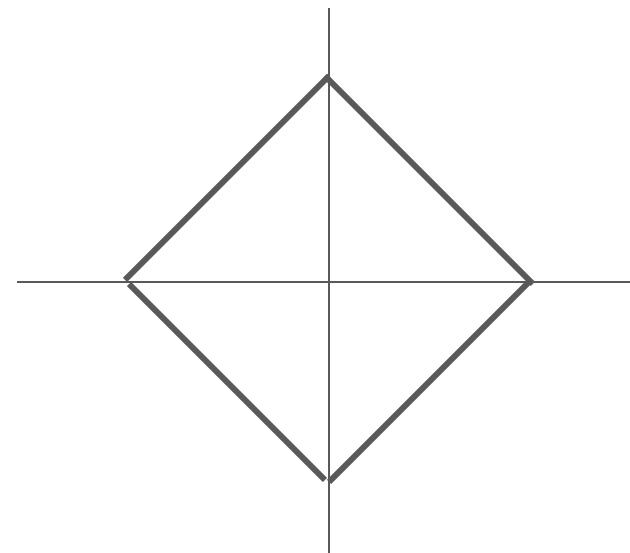


K=5

## ■ 距离度量函数

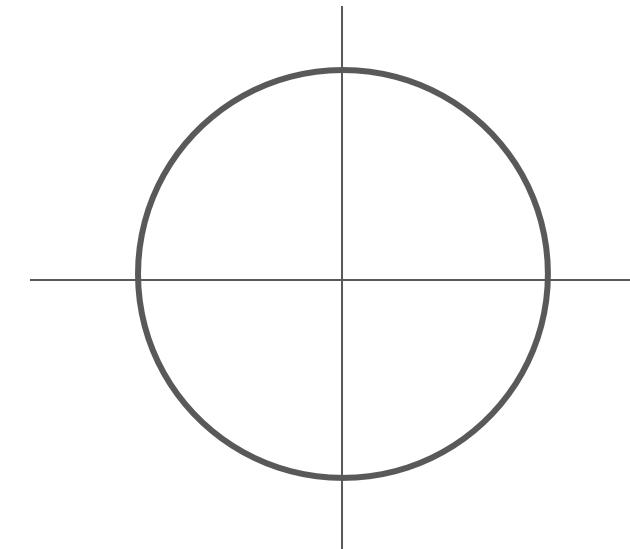
### L1 (Manhattan) 距离

$$d_1(I_1, I_2) = \sum_p |I_1^p - I_2^p|$$



### L2 (Euclidean) 距离

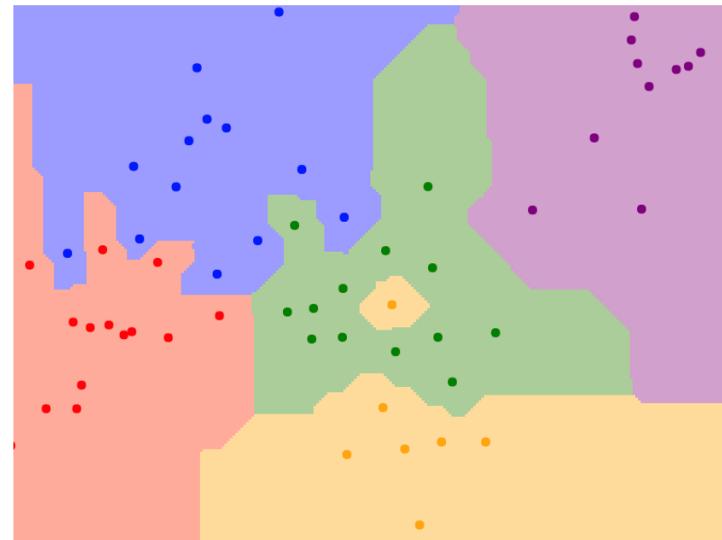
$$d_2(I_1, I_2) = \sqrt{\sum_p (I_1^p - I_2^p)^2}$$



## ■ 距离度量函数

### L1 (Manhattan) 距离

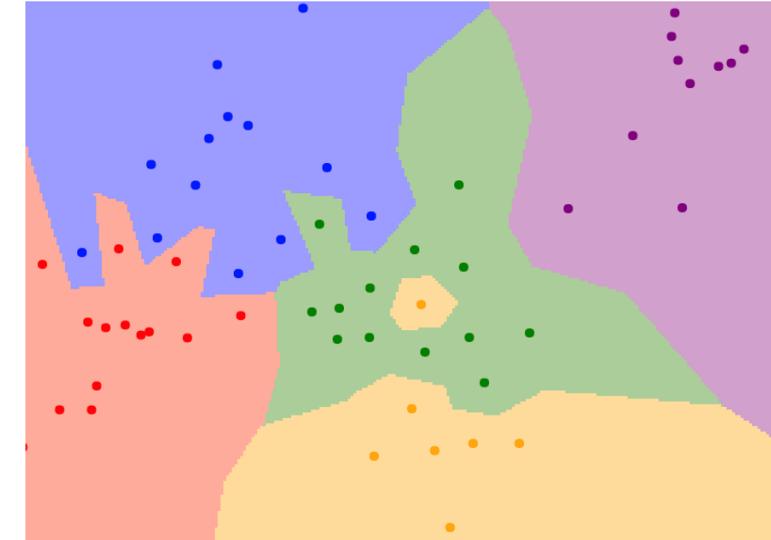
$$d_1(I_1, I_2) = \sum_p |I_1^p - I_2^p|$$



K=1

### L2 (Euclidean) 距离

$$d_2(I_1, I_2) = \sqrt{\sum_p (I_1^p - I_2^p)^2}$$



K=1

## ■ K-NN 超参数

- 超参数：算法本身的设置
- k的最佳值是什么？
- 最好的距离度量函数是什么？
- 超参数的选择
- 非常依赖问题/数据集
- 尝试不同方法，看看哪种效果最好

## ■ 设置超参数

- Idea 1：选择在训练集上表现最好的超参数
- 不好的选择！为什么？
- **K=1 在训练集上是表现最好的超参数，但在测试集上的效果可能很差，难以泛化到测试集上**

train

## ■ 设置超参数

- Idea 2：选择在测试集上表现最好的超参数
- 被禁止的选择！为什么？
- 数据泄露！
- 不能在训练时以任何方式接触测试数据！



## ■ 设置超参数

■ Idea 3：将原始训练集 A 划分为训练集 B + 验证集 C

■ 在训练集 B 上训练模型

■ 在验证集 C 上选择模型超参数

■ 在测试集上进行测试

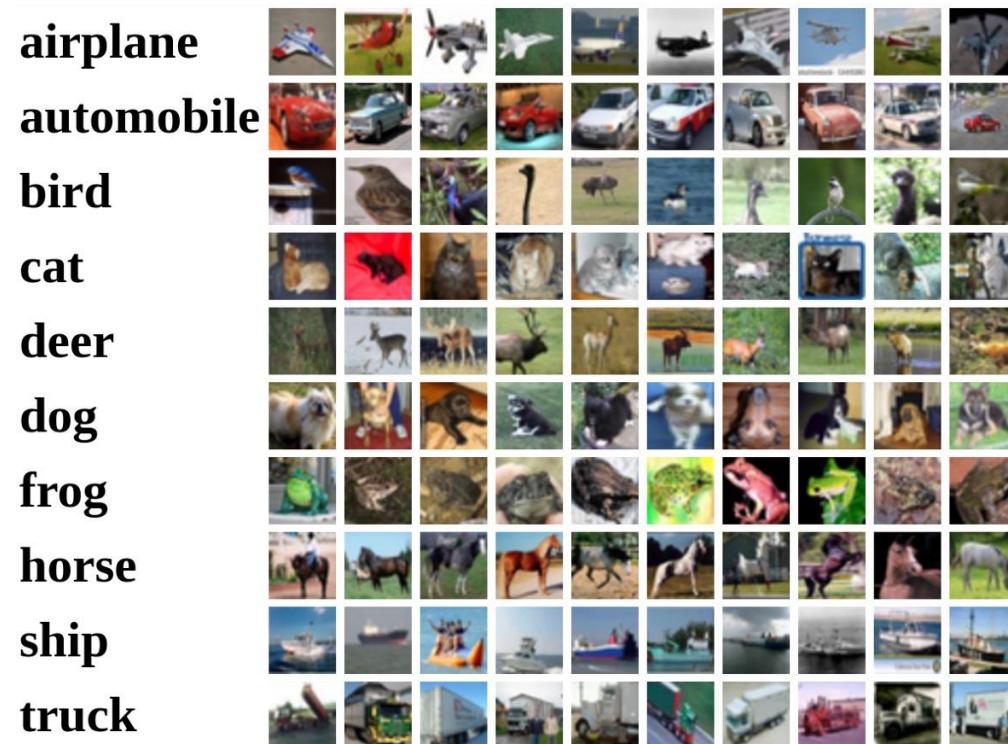
train	validation	test
-------	------------	------

- 交叉验证：将训练数据拆分为多个部分，分别使用每个部分作为验证，并将结果取平均值
- 一般用于小数据集，深度学习中不常用

fold 1	fold 2	fold 3	fold 4	fold 5	test
fold 1	fold 2	fold 3	fold 4	fold 5	test
fold 1	fold 2	fold 3	fold 4	fold 5	test
fold 1	fold 2	fold 3	fold 4	fold 5	test
fold 1	fold 2	fold 3	fold 4	fold 5	test

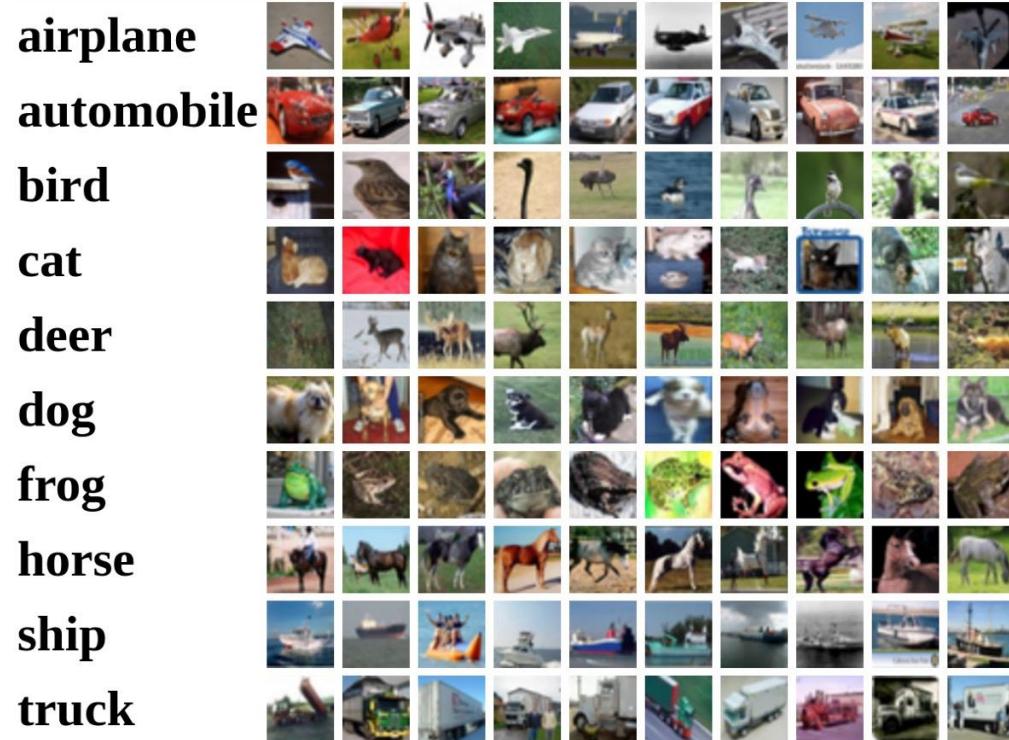
## ■ 例子：CIFAR-10 数据集

■ 10 个类别，50000 张训练图像，10000 张测试图像

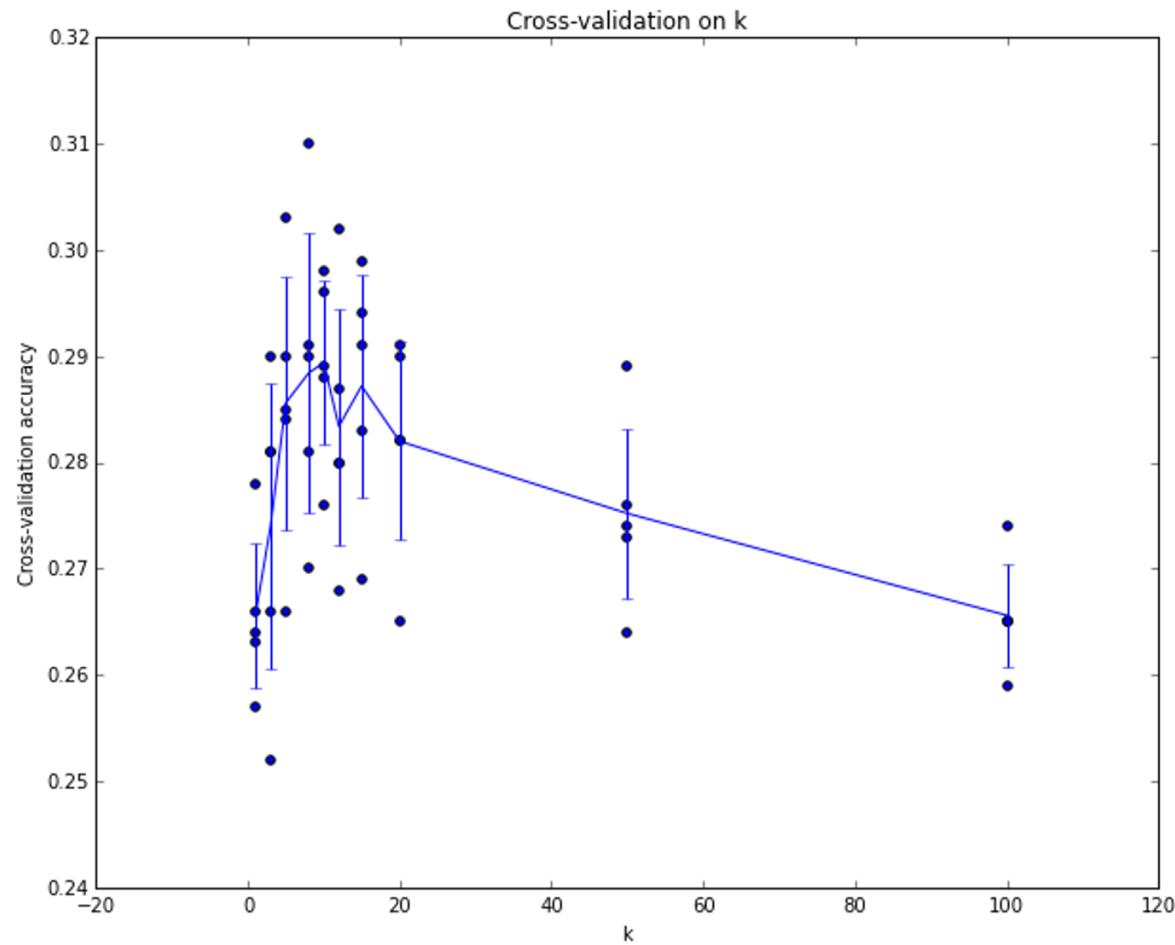


## ■ 例子：CIFAR-10 数据集

### ■ 右侧：测试图像，及其最相似的训练图像



- 例子：设置超参数
  - 5-折交叉验证
  - 点：单折验证结果
  - $K=7$  时效果最好



# K-NN 最近邻分类器

## ■ 最近邻分类效果

■ 看起来很像

■ 但存在错误



# K-NN 最近邻分类器

## ■ 这的结果像什么?

- 图像检索!
- 区别?
- 预测目的不同!



- 不要直接使用像素间的距离进行度量!
- 像素间的距离度量的泛化性和稳定性都很差

Original



Occluded



Shifted (1 pixel)



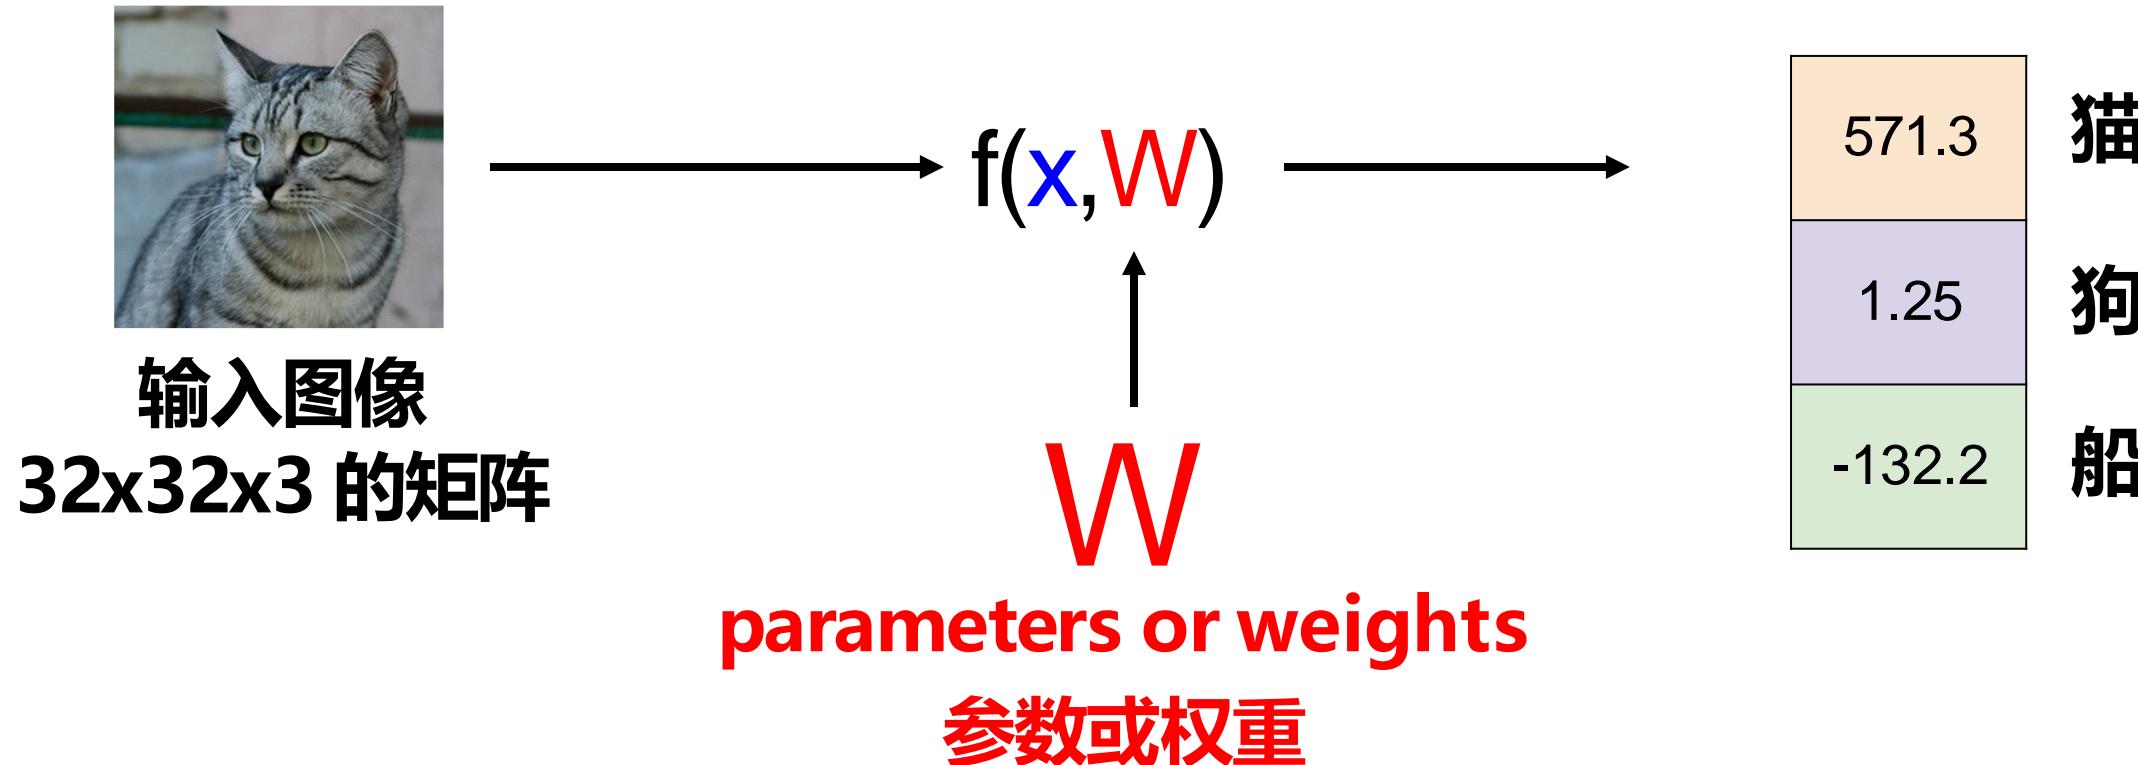
Tinted



# 大 纲

- 图像分类
- K-NN 最近邻分类器
- 线性分类器

## ■ 线性分类器的定义



## ■ 线性分类器的定义

$$f(x, W) = Wx$$



输入图像  
32x32x3 的矩阵

$$\xrightarrow{f(x, W)}$$



W

parameters or weights

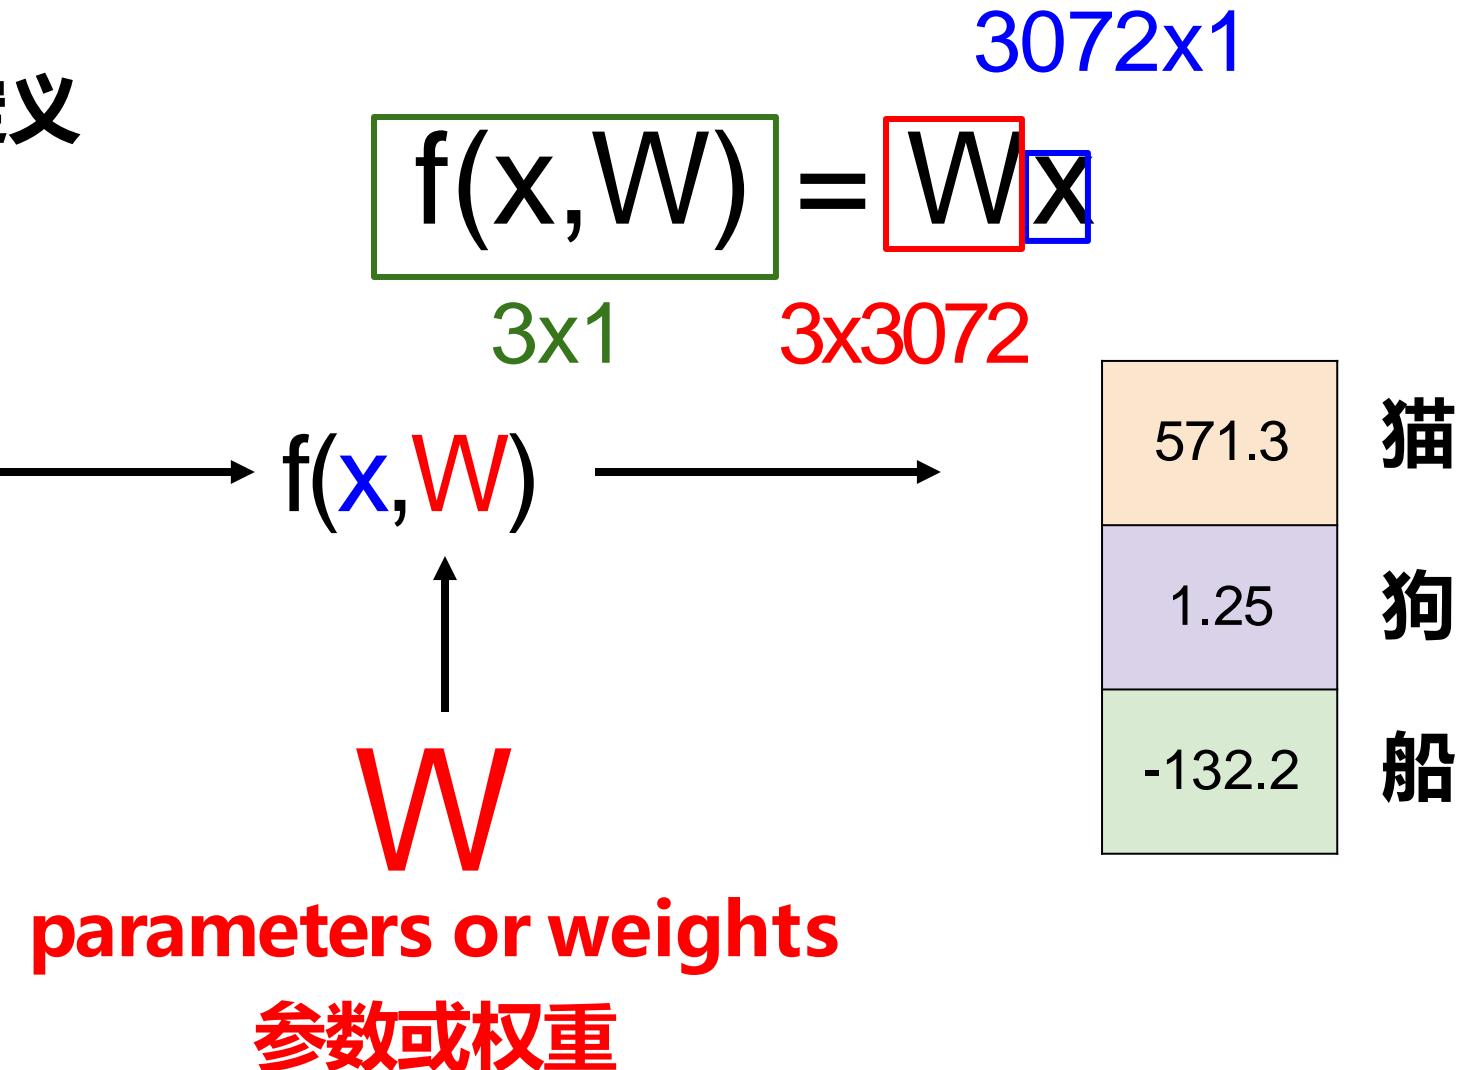
参数或权重

571.3
1.25
-132.2

猫  
狗  
船

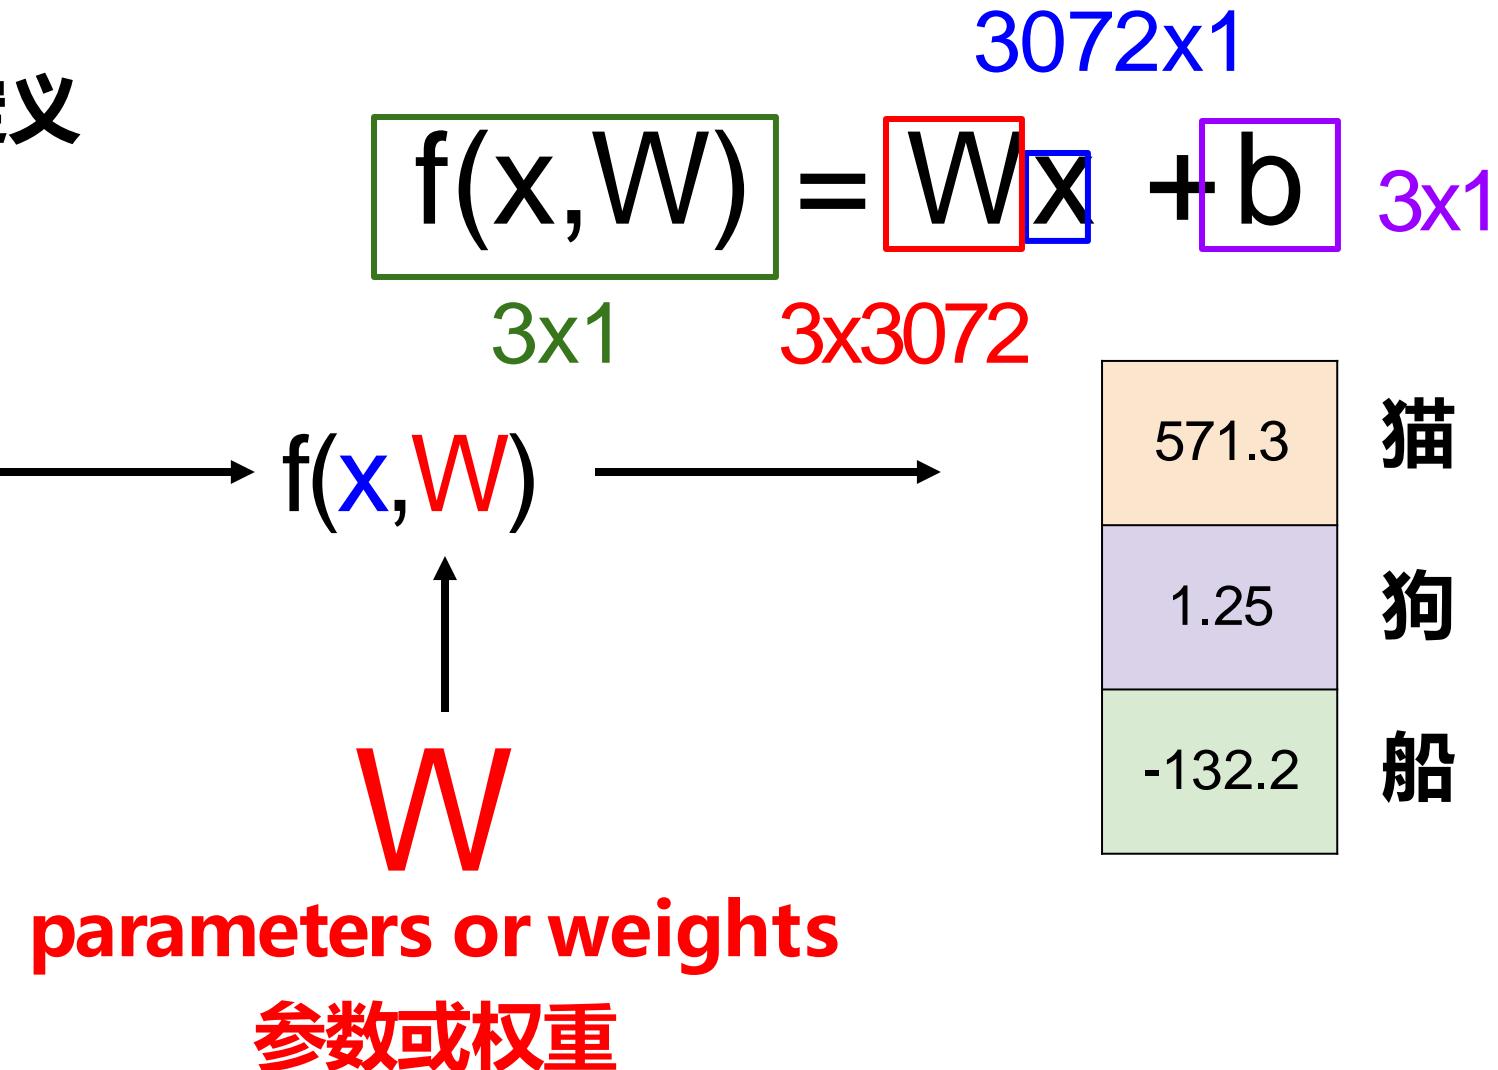
## ■ 线性分类器的定义

  
输入图像  
 $32 \times 32 \times 3$  的矩阵



## ■ 线性分类器的定义

 输入图像  
 $32 \times 32 \times 3$  的矩阵



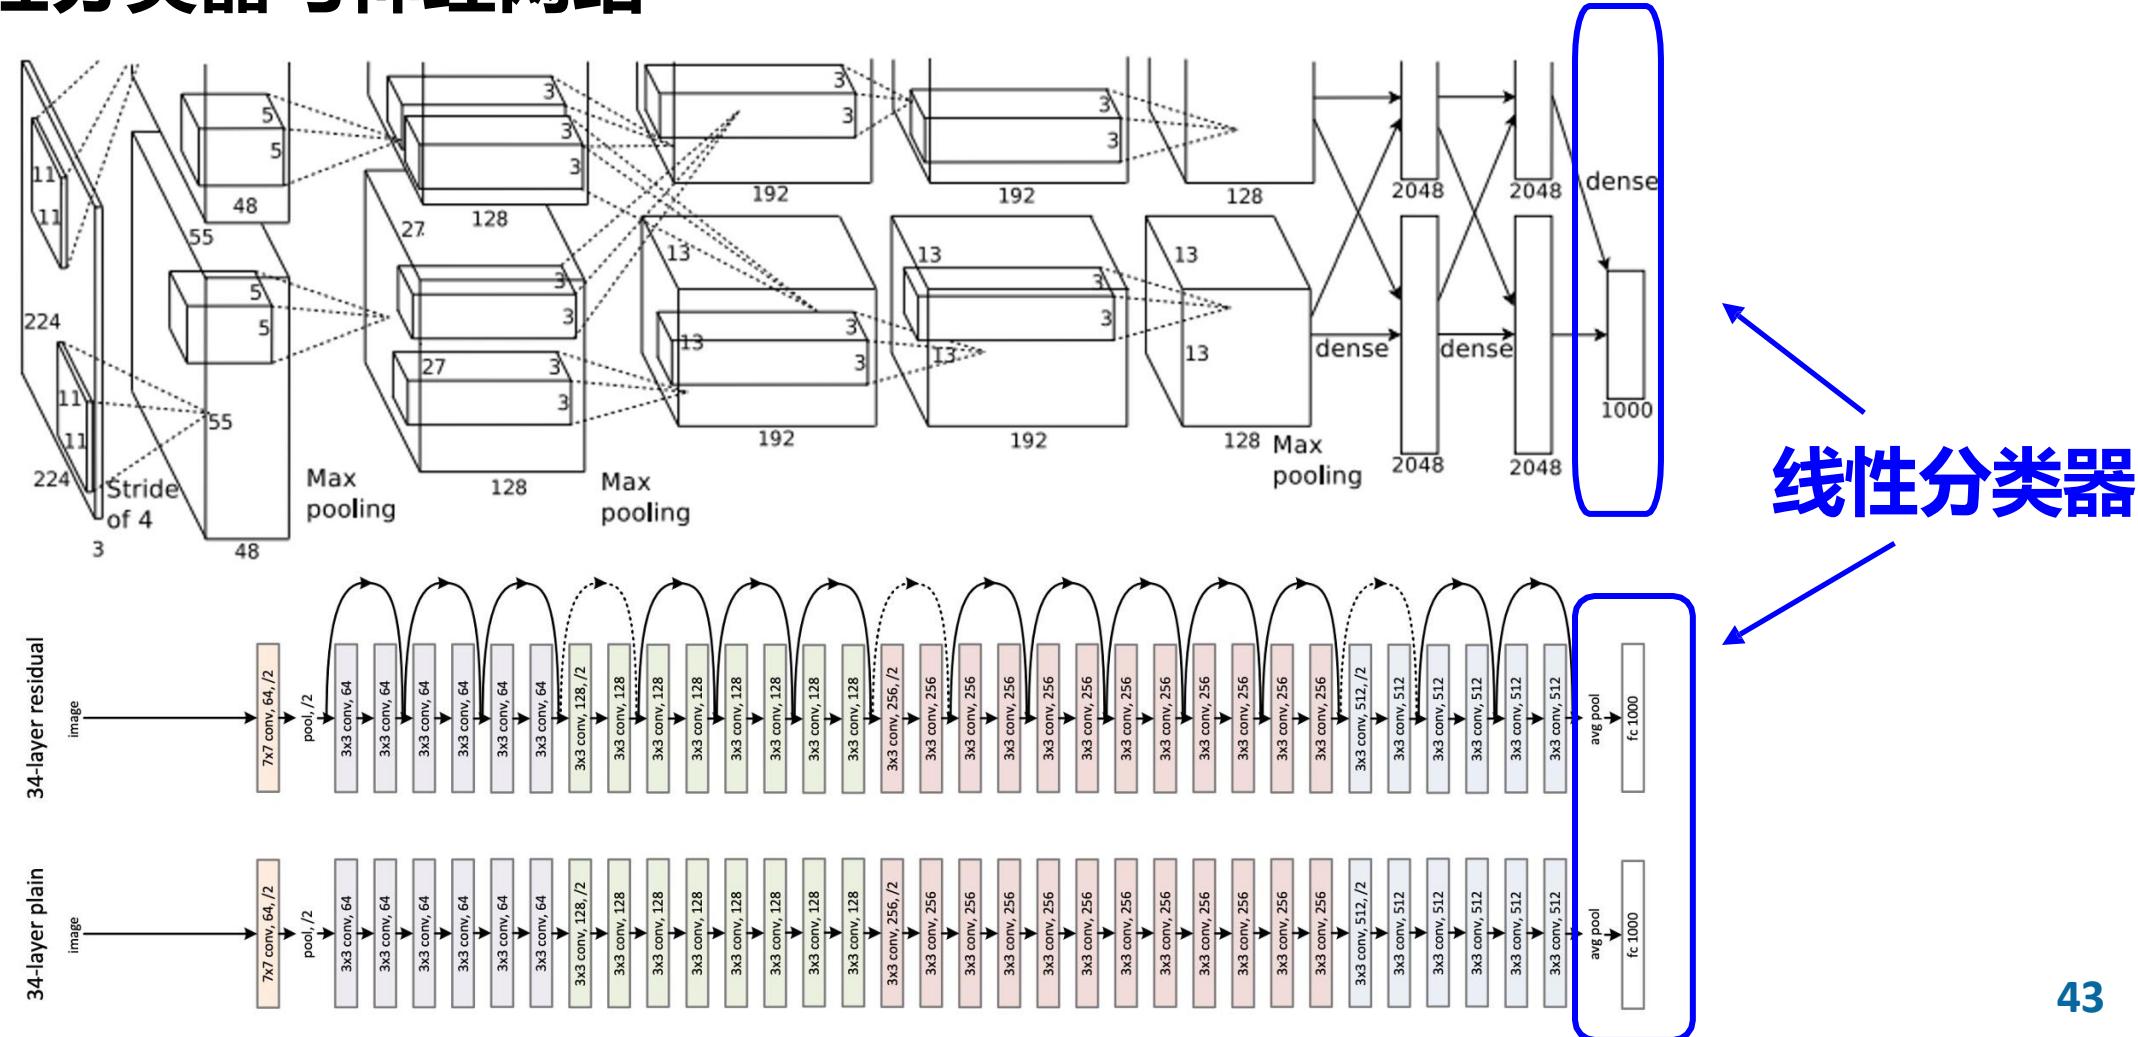
## ■ 线性分类器与神经网络

线性分类器

神经网络

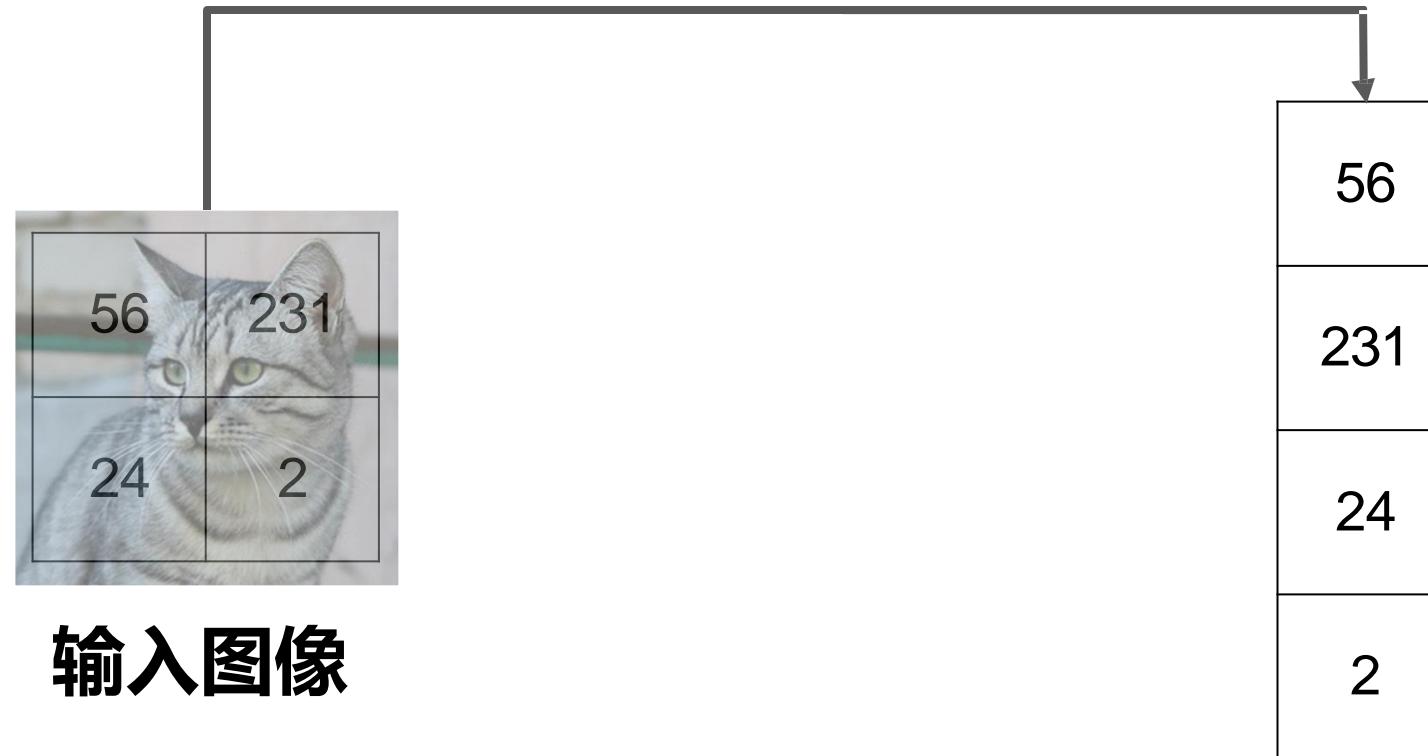


## ■ 线性分类器与神经网络



- 例子：含有  $2 \times 2$  像素的图像，数据集包含 3 个类别

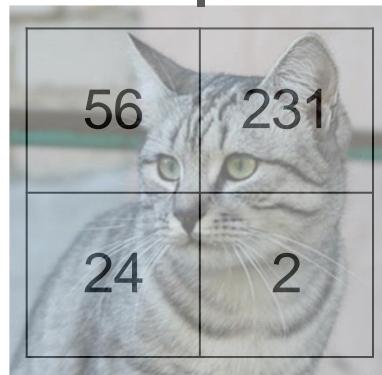
将图像像素平铺为一个向量



输入图像

- 例子：含有  $2 \times 2$  像素的图像，数据集包含 3 个类别

将图像像素平铺为一个向量



输入图像

0.2	-0.5	0.1	2.0
1.5	1.3	2.1	0.0
0	0.25	0.2	-0.3

$W$

代数视角理解线性分类器

56
231
24
2

+

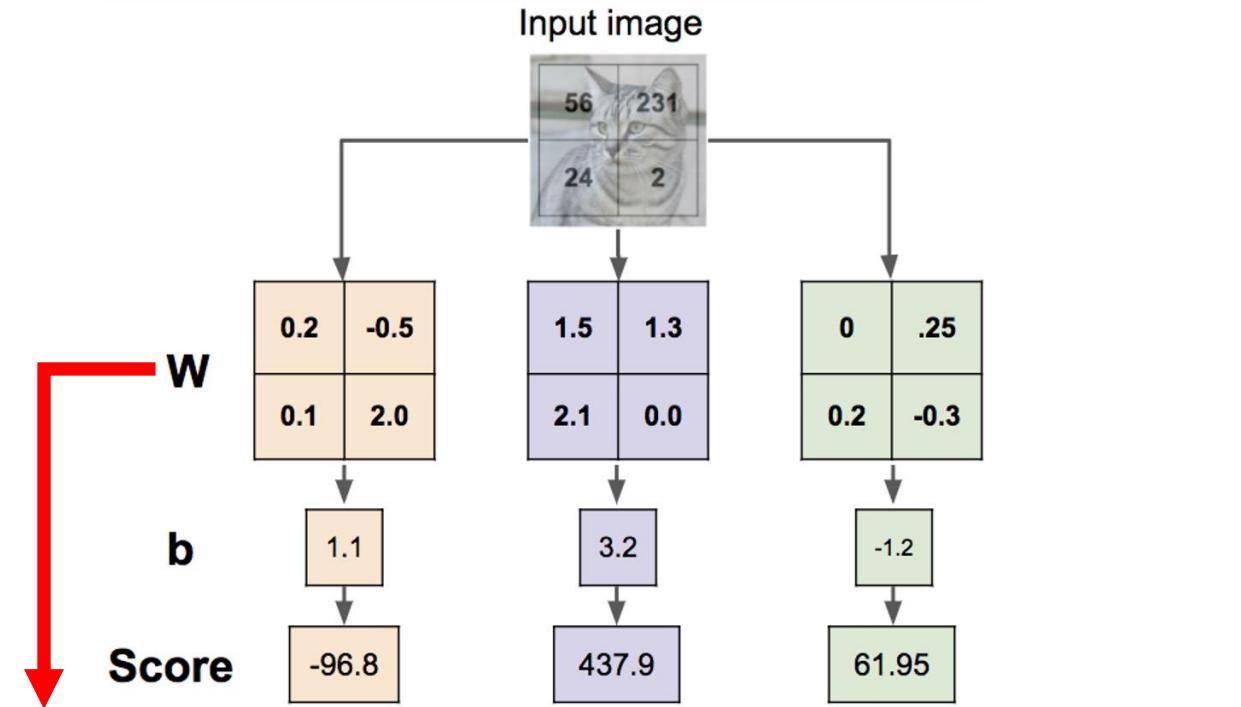
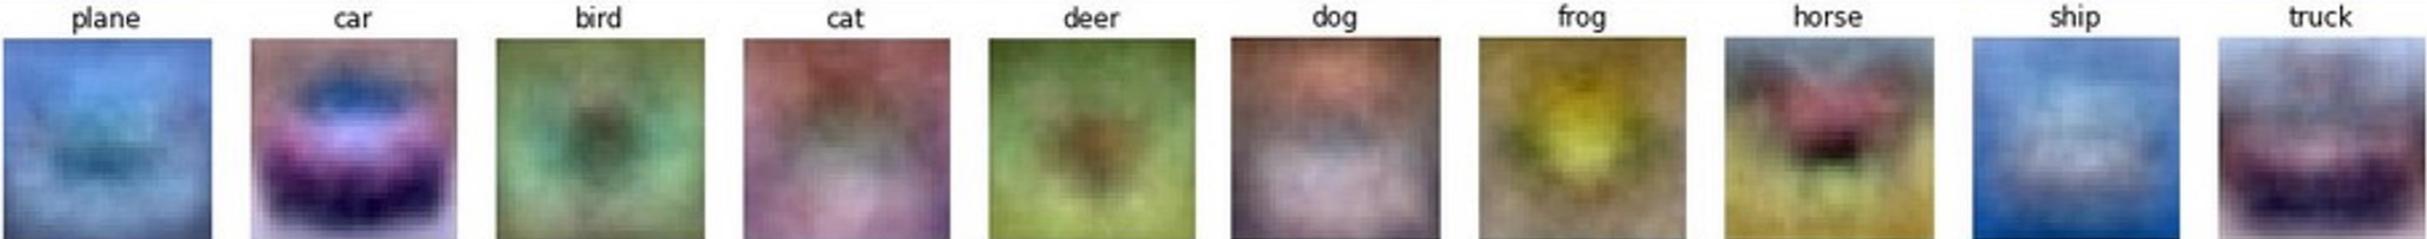
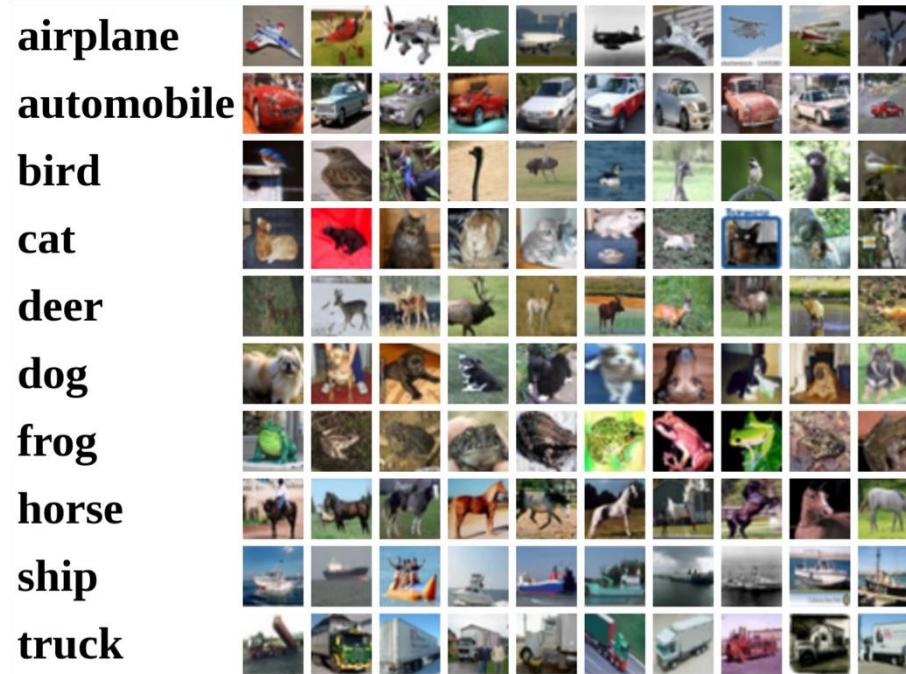
1.1
3.2
-1.2

=

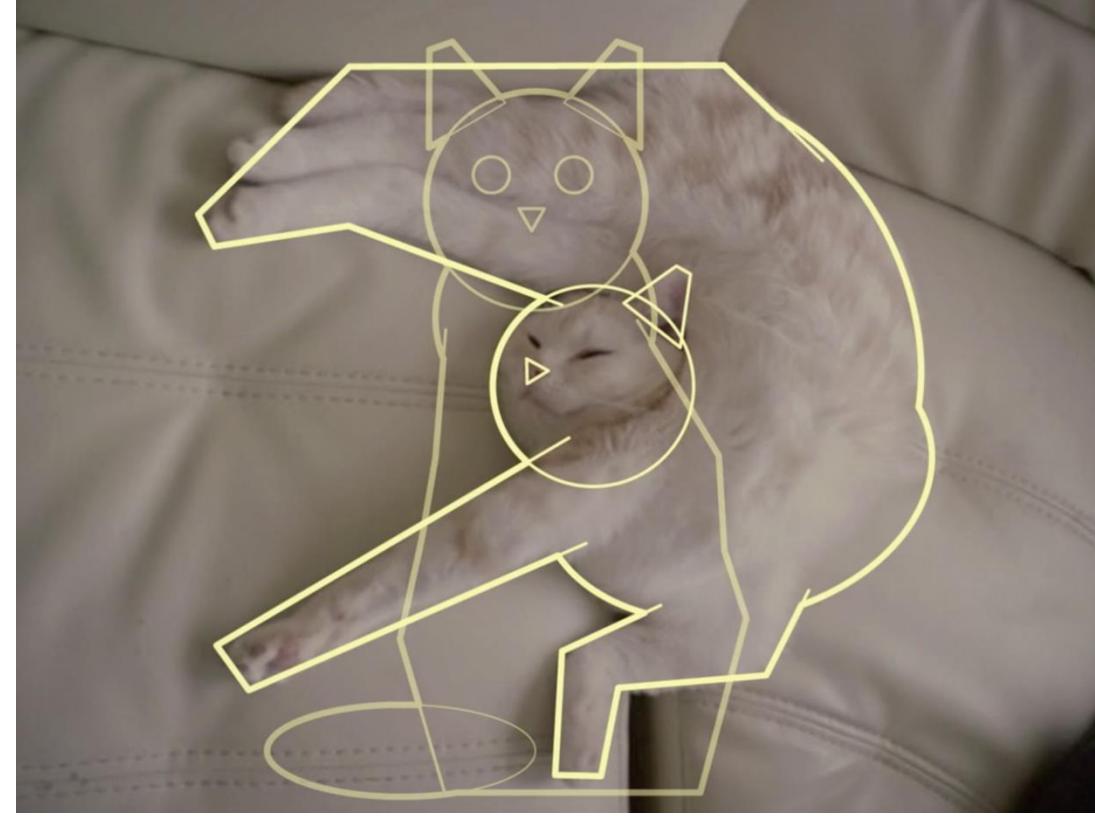
-96.8
437.9
61.95

Cat score  
Dog score  
Ship score

## ■ 视觉视角理解线性分类器



# 线性分类器



plane



car



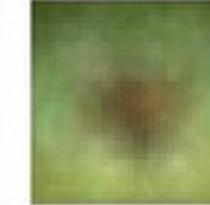
bird



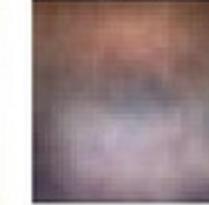
cat



deer



dog



frog



horse



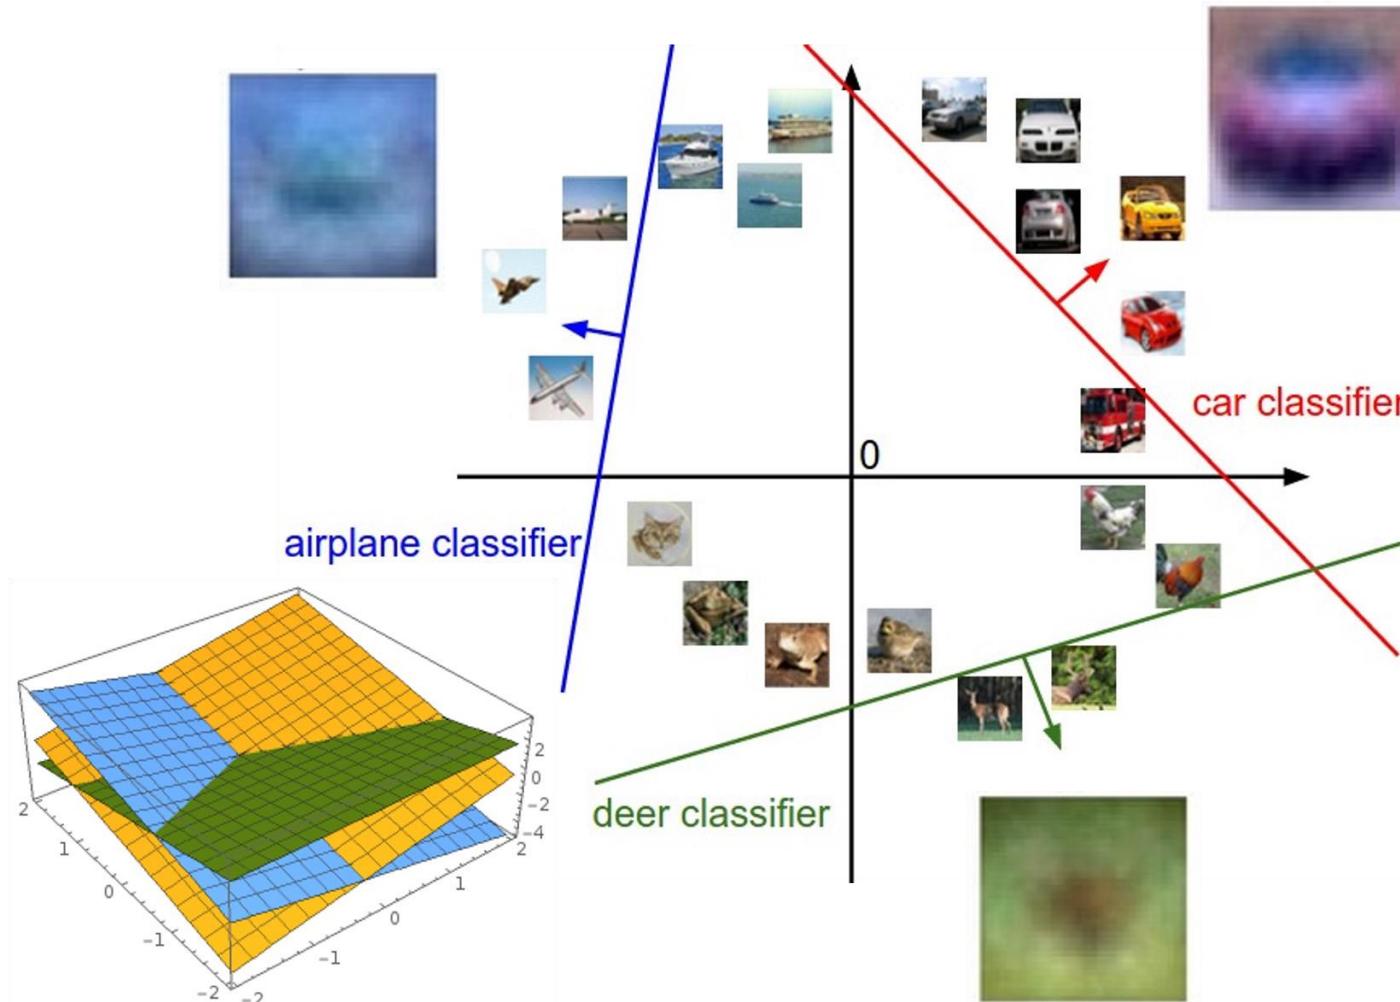
ship



truck



## ■ 几何视角理解线性分类器



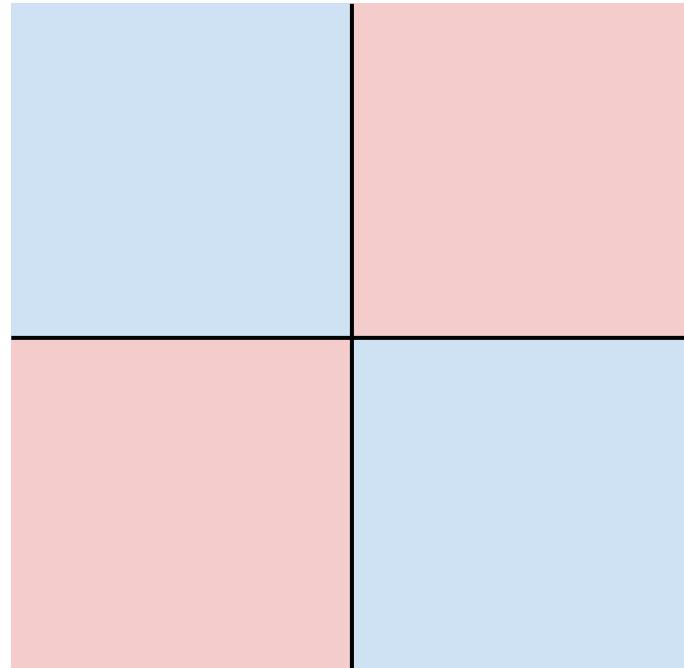
$$f(x, W) = Wx + b$$



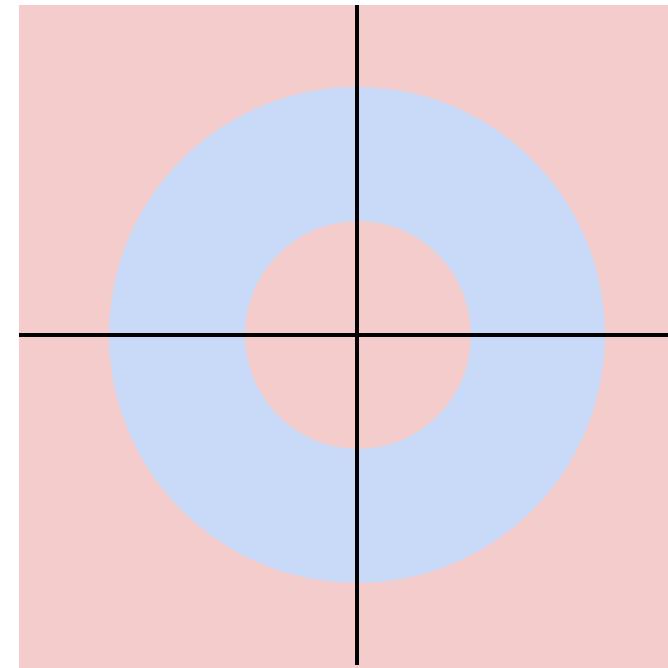
输入图像  
32x32x3 的矩阵

## ■ 线性分类器难以处理的情况

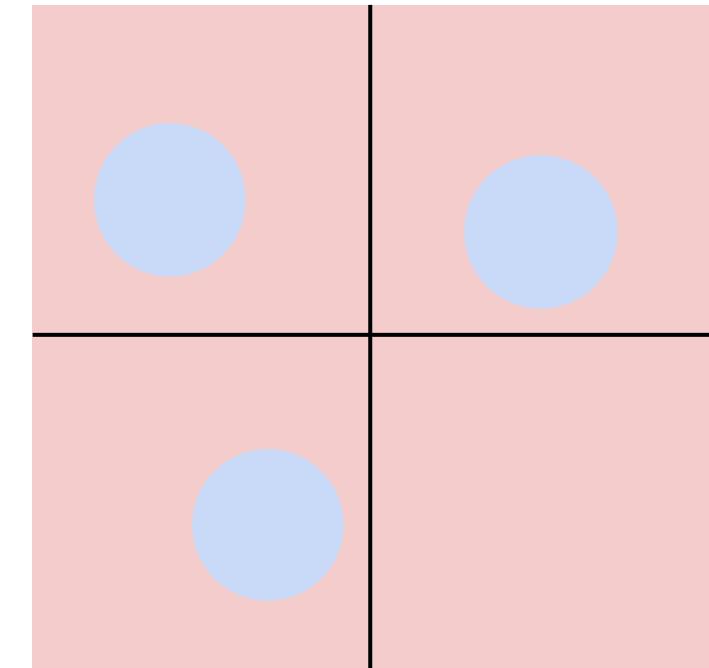
类别一：第一、三象限  
类别二：第二、四象限



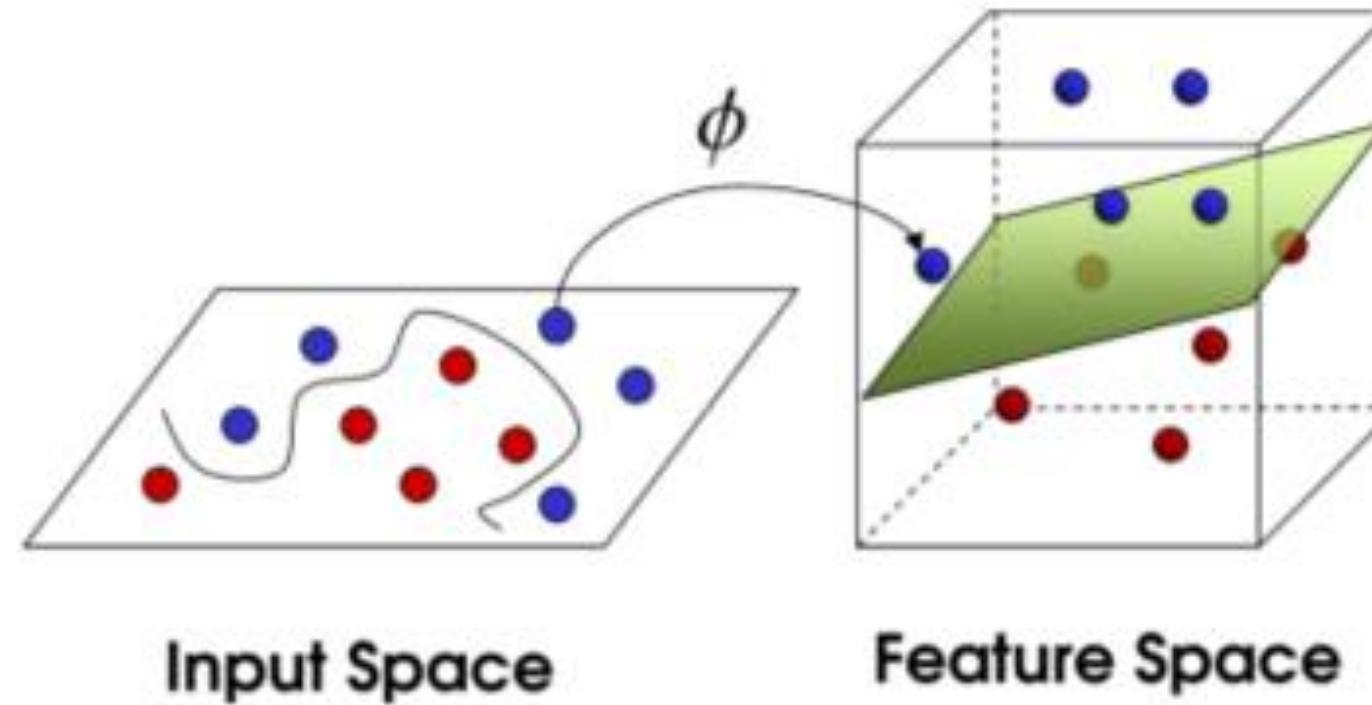
类别一： $1 \leq L2 \text{ norm} \leq 2$   
类别二：其他



类别一：三个圆  
类别二：其他



- 低维不可分，高维可分
- 映射到高维空间，依然可以进行线性分类



## ■ 训练线性分类器的参数 W



airplane	-3.45	-0.51	3.42
automobile	-8.87	<b>6.04</b>	4.64
bird	0.09	5.31	2.65
cat	<b>2.9</b>	-4.22	5.1
deer	4.48	-4.19	2.64
dog	8.02	3.58	5.55
frog	3.78	4.49	<b>-4.34</b>
horse	1.06	-4.37	-1.5
ship	-0.36	-2.09	-4.79
truck	-0.72	-2.93	6.14

- 定义一个损失函数，量化对训练数据中预测分数的满意度
- 提出一种有效的优化方法找到最小化损失函数的参数

## ■ 训练线性分类器的参数 $W$

$$f(x, W) = Wx$$



cat	3.2	1.3	2.2
car	5.1	4.9	2.5
frog	-1.7	2.0	-3.1

- 损失函数：衡量当前分类器的好坏
- 给定包含  $N$  个样本的数据集：

$$\{(x_i, y_i)\}_{i=1}^N$$

- 损失函数为：
$$L = \frac{1}{N} \sum_i L_i(f(x_i, W), y_i)$$

## ■ 多类别 SVM Loss

$$f(x, W) = Wx$$



cat	3.2	1.3	2.2
car	5.1	4.9	2.5
frog	-1.7	2.0	-3.1

■ 对于一个样本:  $(x_i, y_i)$

■ 预测得分为:  $s = f(x_i, W)$

■ SVM Loss 为:

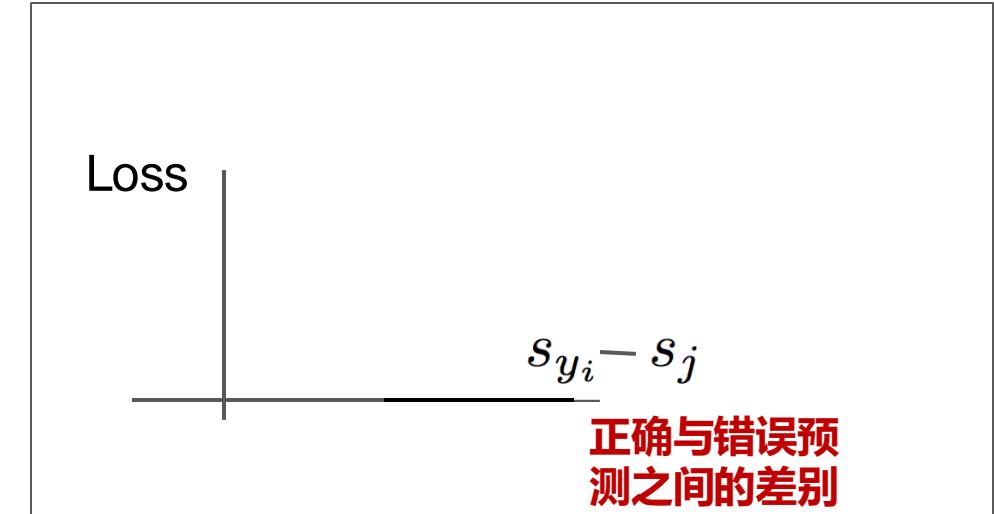
$$\begin{aligned} L_i &= \sum_{j \neq y_i} \begin{cases} 0 & \text{if } s_{y_i} \geq s_j + 1 \\ s_j - s_{y_i} + 1 & \text{otherwise} \end{cases} \\ &= \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1) \end{aligned}$$

## ■ 多类别 SVM Loss

$$f(x, W) = Wx$$



cat	3.2	1.3	2.2
car	5.1	4.9	2.5
frog	-1.7	2.0	-3.1



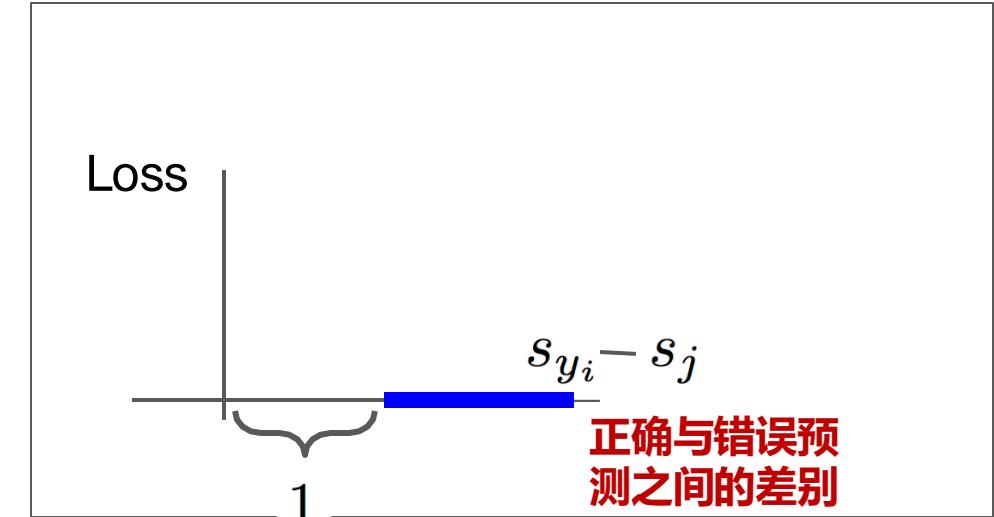
$$\begin{aligned} L_i &= \sum_{j \neq y_i} \begin{cases} 0 & \text{if } s_{y_i} \geq s_j + 1 \\ s_j - s_{y_i} + 1 & \text{otherwise} \end{cases} \\ &= \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1) \end{aligned}$$

## ■ 多类别 SVM Loss

$$f(x, W) = Wx$$



cat	3.2	1.3	2.2
car	5.1	4.9	2.5
frog	-1.7	2.0	-3.1



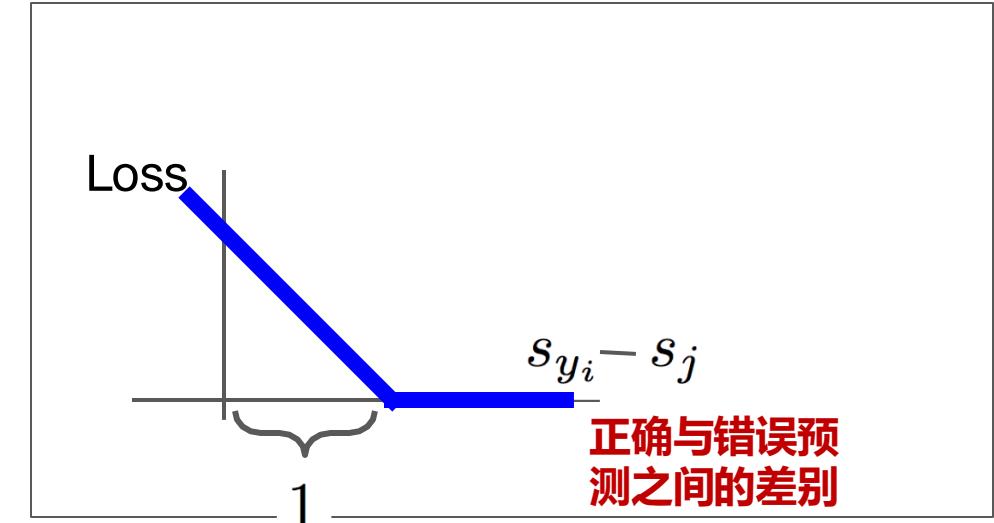
$$\begin{aligned} L_i &= \sum_{j \neq y_i} \begin{cases} 0 & \text{if } s_{y_i} \geq s_j + 1 \\ s_j - s_{y_i} + 1 & \text{otherwise} \end{cases} \\ &= \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1) \end{aligned}$$

## ■ 多类别 SVM Loss

$$f(x, W) = Wx$$



cat	3.2	1.3	2.2
car	5.1	4.9	2.5
frog	-1.7	2.0	-3.1



$$\begin{aligned} L_i &= \sum_{j \neq y_i} \begin{cases} 0 & \text{if } s_{y_i} \geq s_j + 1 \\ s_j - s_{y_i} + 1 & \text{otherwise} \end{cases} \\ &= \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1) \end{aligned}$$

## ■ 多类别 SVM Loss $f(x, W) = Wx$



$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

cat	3.2	1.3	2.2
car	5.1	4.9	2.5
frog	-1.7	2.0	-3.1

## ■ 多类别 SVM Loss

$$f(x, W) = Wx$$



cat	3.2	1.3	2.2
car	5.1	4.9	2.5
frog	-1.7	2.0	-3.1
Loss:	<b>2.9</b>		

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

$$= \max(0, 5.1 - 3.2 + 1)$$

$$+ \max(0, -1.7 - 3.2 + 1)$$

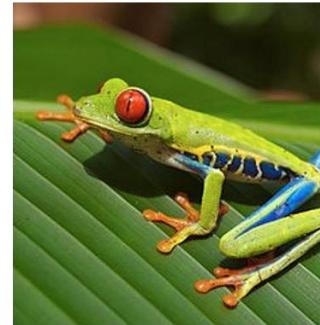
$$= \max(0, 2.9) + \max(0, -3.9)$$

$$= 2.9 + 0$$

$$= 2.9$$

## ■ 多类别 SVM Loss

$$f(x, W) = Wx$$



cat	3.2	1.3	2.2
car	5.1	4.9	2.5
frog	-1.7	2.0	-3.1
<b>Loss:</b>	<b>2.9</b>	<b>0</b>	

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

$$\begin{aligned}&= \max(0, 1.3 - 4.9 + 1) \\&\quad + \max(0, 2.0 - 4.9 + 1) \\&= \max(0, -2.6) + \max(0, -1.9) \\&= 0 + 0 \\&= 0\end{aligned}$$

## ■ 多类别 SVM Loss

$$f(x, W) = Wx$$



cat	3.2	1.3
car	5.1	4.9
frog	-1.7	2.0
<b>Loss:</b>	<b>2.9</b>	<b>0</b>

2.2
2.5
-3.1
<b>12.9</b>

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

$$\begin{aligned}&= \max(0, 2.2 - (-3.1) + 1) \\&\quad + \max(0, 2.5 - (-3.1) + 1) \\&= \max(0, 6.3) + \max(0, 6.6) \\&= 6.3 + 6.6 \\&= 12.9\end{aligned}$$

## ■ 多类别 SVM Loss

$$f(x, W) = Wx$$



cat	3.2	1.3	2.2
car	5.1	4.9	2.5
frog	-1.7	2.0	-3.1
<b>Loss:</b>	<b>2.9</b>	<b>0</b>	<b>12.9</b>

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

最终的损失为：

$$L = \frac{1}{N} \sum_{i=1}^N L_i$$

$$\begin{aligned} L &= (2.9 + 0 + 12.9)/3 \\ &= 5.27 \end{aligned}$$

## ■ 多类别 SVM Loss $f(x, W) = Wx$



cat	1.3
car	4.9
frog	2.0
<b>Loss:</b>	<b>0</b>

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

- 如果 car 的预测得分降低0.5，会发生什么情况？

## ■ 多类别 SVM Loss $f(x, W) = Wx$



cat	3.2	1.3	2.2
car	5.1	4.9	2.5
frog	-1.7	2.0	-3.1
<b>Loss:</b>	<b>2.9</b>	<b>0</b>	<b>12.9</b>

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

## ■ 损失函数的最小和最大值分别可能是多少?

## ■ 多类别 SVM Loss

$$f(x, W) = Wx$$



cat	3.2	1.3	2.2
car	5.1	4.9	2.5
frog	-1.7	2.0	-3.1
<b>Loss:</b>	<b>2.9</b>	<b>0</b>	<b>12.9</b>

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

- 如果我们将损失函数中的 sum 替换为 mean, 会出现什么情况?

## ■ 多类别 SVM Loss

$$f(x, W) = Wx$$

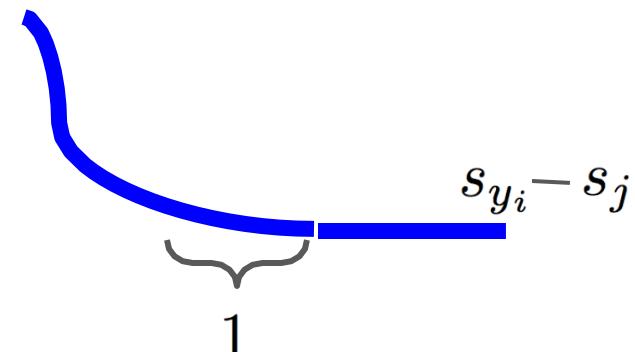


cat	3.2	1.3	2.2
car	5.1	4.9	2.5
frog	-1.7	2.0	-3.1
<b>Loss:</b>	<b>2.9</b>	<b>0</b>	<b>12.9</b>

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

■ 如果我们将损失函数替  
换为下式?

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)^2$$



## ■ 多类别 SVM Loss

$$f(x, W) = Wx$$



cat	3.2	1.3	2.2
car	5.1	4.9	2.5
frog	-1.7	2.0	-3.1
<b>Loss:</b>	<b>2.9</b>	<b>0</b>	<b>12.9</b>

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

- 训练初始时，W 非常小以至于 s 约为 0，那么  $L_i$  会是什么样的？

## ■ 多类别 SVM Loss

$$f(x, W) = Wx$$



cat	3.2	1.3	2.2
car	5.1	4.9	2.5
frog	-1.7	2.0	-3.1
<b>Loss:</b>	<b>2.9</b>	<b>0</b>	<b>12.9</b>

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

■ 如果我们对所有类别求和，会怎样？（包括  $j = y_i$  的情况）

## ■ 多类别 SVM Loss 代码样例

```
def L_i_vectorized(x, y, W):
    scores = W.dot(x)
    margins = np.maximum(0, scores - scores[y] + 1)
    margins[y] = 0
    loss_i = np.sum(margins)
    return loss_i
```

## ■ 线性分类器 Softmax Loss



cat	3.2
car	5.1
frog	-1.7

## ■ 线性分类器 Softmax Loss



$$s = f(x_i; W)$$

$$P(Y = k | X = x_i) = \frac{e^{s_k}}{\sum_j e^{s_j}}$$

Softmax  
函数

cat	3.2
car	5.1
frog	-1.7

## ■ 线性分类器 Softmax Loss



$$s = f(x_i; W)$$

$$P(Y = k | X = x_i) = \frac{e^{s_k}}{\sum_j e^{s_j}}$$

Softmax  
函数

概率必须  
 $\geq 0$

cat  
car  
frog

3.2
5.1
-1.7

$\exp$

24.5
164.0
0.18

未归一化的 log-  
probabilities / logits

未归一化的  
probabilities

## ■ 线性分类器 Softmax Loss



$$s = f(x_i; W)$$

概率必须  
 $\geq 0$

$$P(Y = k | X = x_i) = \frac{e^{s_k}}{\sum_j e^{s_j}}$$

Softmax  
函数

cat  
car  
frog

3.2
5.1
-1.7

exp

24.5
164.0
0.18

normalize

0.13
0.87
0.00

未归一化的 log-  
probabilities / logits

未归一化的  
probabilities

概率

## ■ 线性分类器 Softmax Loss



$$s = f(x_i; W)$$

概率必须  
 $\geq 0$

$$P(Y = k | X = x_i) = \frac{e^{s_k}}{\sum_j e^{s_j}}$$

Softmax  
函数

cat  
car  
frog

3.2
5.1
-1.7

exp

24.5
164.0
0.18

normalize

0.13
0.87
0.00

$$L_i = -\log P(Y = y_i | X = x_i)$$

未归一化的 log-  
probabilities / logits

未归一化的  
probabilities

概率

## ■ 线性分类器 Softmax Loss



$$s = f(x_i; W)$$

概率必须  
 $\geq 0$

$$P(Y = k | X = x_i) = \frac{e^{s_k}}{\sum_j e^{s_j}}$$

Softmax  
函数

cat  
car  
frog

3.2
5.1
-1.7

exp

24.5
164.0
0.18

normalize

0.13
0.87
0.00

→ compare ←

1.00
0.00
0.00

未归一化的 log-  
probabilities / logits

未归一化的  
probabilities

概率

正确标签  
的概率 74

## ■ 线性分类器 Softmax Loss



$$s = f(x_i; W)$$

概率必须  
 $\geq 0$

cat	3.2
car	5.1
frog	-1.7

未归一化的 log-  
probabilities / logits

exp

24.5
164.0
0.18

未归一化的  
probabilities

normalize

0.13
0.87
0.00

概率

$$P(Y = k | X = x_i) = \frac{e^{s_k}}{\sum_j e^{s_j}}$$

Softmax  
函数

$$L_i = -\log P(Y = y_i | X = x_i)$$

→ compare ←

1.00

Kullback–Leibler  
divergence

0.00

$$D_{KL}(P || Q) = \sum_y P(y) \log \frac{P(y)}{Q(y)}$$

正确标签  
的概率 75

## ■ 线性分类器 Softmax Loss



$$s = f(x_i; W)$$

概率必须  
 $\geq 0$

cat	3.2
car	5.1
frog	-1.7

未归一化的 log-  
probabilities / logits

未归一化的  
probabilities

exp	24.5
	164.0
	0.18

未归一化的  
probabilities

normalize

0.13
0.87
0.00

概率

$$P(Y = k | X = x_i) = \frac{e^{s_k}}{\sum_j e^{s_j}}$$

Softmax  
函数

$$L_i = -\log P(Y = y_i | X = x_i)$$

概率之和  
必须=1

→ compare ←	1.00
Cross Entropy	0.00
$H(P, Q) = H(p) + D_{KL}(P \  Q)$	0.00

正确标签  
的概率 76

## ■ 线性分类器 Softmax Loss



$$s = f(x_i; W)$$

$$P(Y = k | X = x_i) = \frac{e^{s_k}}{\sum_j e^{s_j}}$$

Softmax  
函数



cat  
car  
frog

3.2
5.1
-1.7

最大化正确类别的概率:  $L_i = -\log P(Y = y_i | X = x_i)$



最终的损失函数形式:

$$L_i = -\log\left(\frac{e^{s_{y_i}}}{\sum_j e^{s_j}}\right)$$

## ■ 线性分类器 Softmax Loss



$$s = f(x_i; W)$$

$$P(Y = k | X = x_i) = \frac{e^{s_k}}{\sum_j e^{s_j}}$$

Softmax  
函数

$$L_i = -\log\left(\frac{e^{s_{y_i}}}{\sum_j e^{s_j}}\right)$$

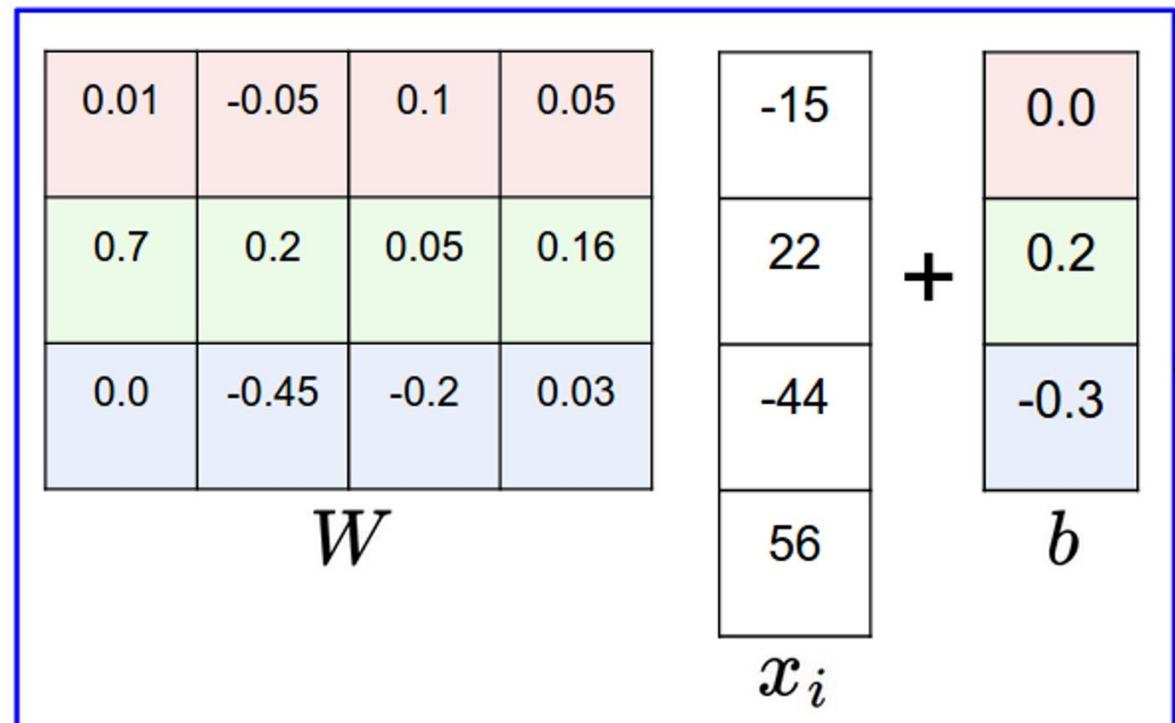
cat  
car  
frog

3.2
5.1
-1.7

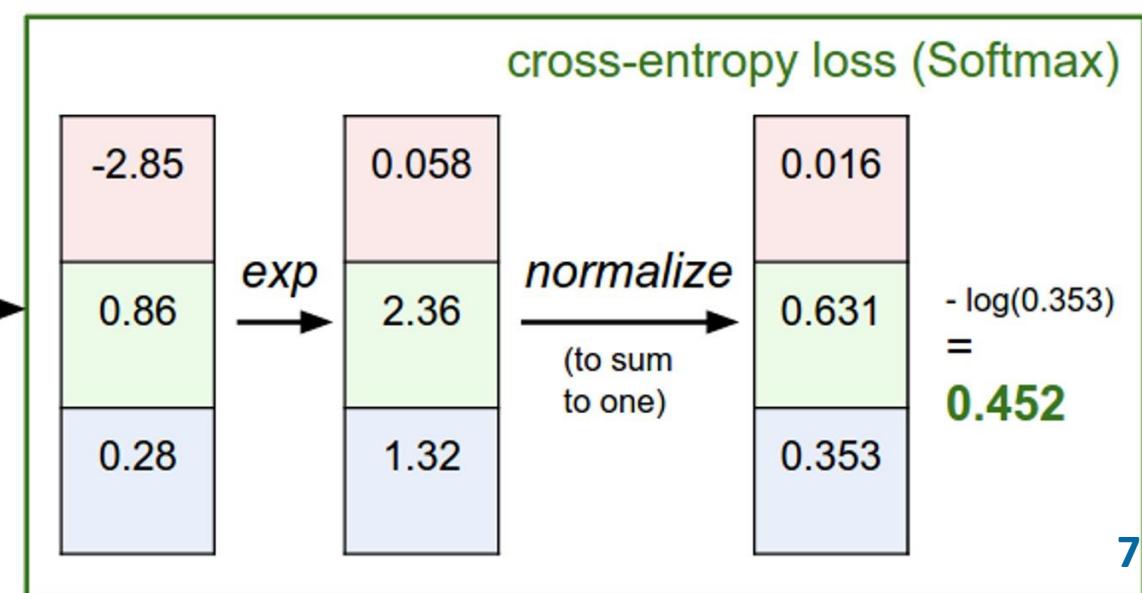
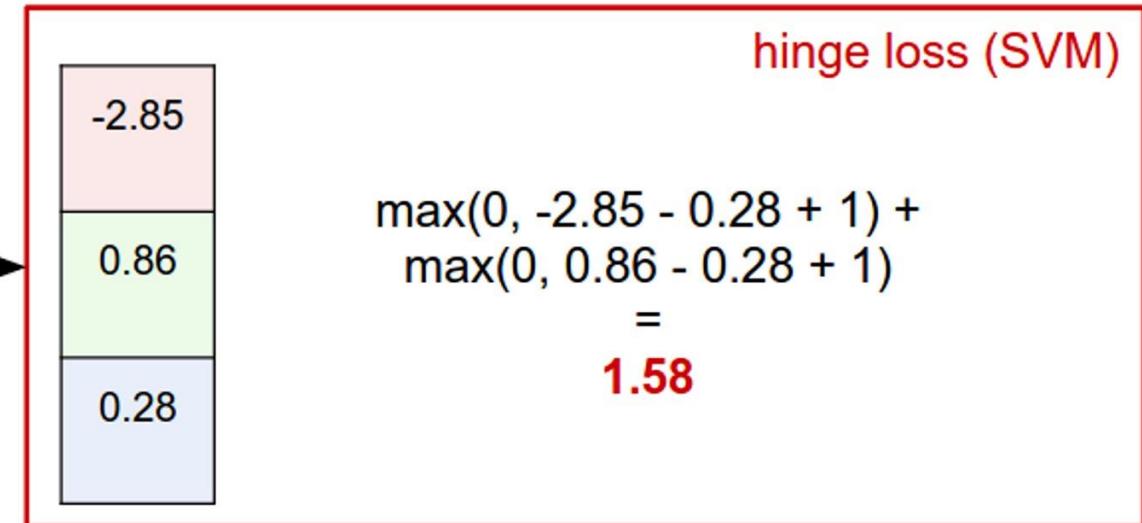
- Softmax 损失  $L_i$  可能的最大值和最小值是多少?
- 在初始化时，所有  $s_j$  将大致相等；假设有 C 个类别，softmax 损失  $L_i$  是多少?
- 如果预测得分  $s_j$  发生轻微扰动， $L_i$  会发生什么?

## ■ Softmax v.s. SVM

matrix multiply + bias offset



$y_i$  2



## ■ 下一节：正则化与优化