数据挖掘

第4章 朴素贝叶斯分类

2024 年 10 月

学习目标

- 掌握分类的概念和基本过程
- 掌握朴素贝叶斯分类原理

南京大學
NANJING UNIVERSITY

目录

分类概念

- 什么是分类?
  - 找出描述和区分数据类或概念的模型，以便能够使用模型预测类标号未知的对象的类标号
- 一般过程
  - 学习阶段
    - 建立描述预先定义的数据类或概念集的分类器
    - 训练集提供了每个训练元组的类标号，分类的学习过程也称为监督学习（supervised learning）
  - 分类阶段
    - 使用定义好的分类器进行分类的过程

分类概念

- 什么是分类?
  - 找出描述和区分数据类或概念的模型，以便能够使用模型预测类标号未知的对象的类标号
- 概念区分
  - 分类与回归
    - 分类是预测分类（离散、无序）标号
    - 回归建立连续值函数模型
  - 分类与聚类
    - 分类是有监督学习，提供了训练元组的类标号
    - 聚类是无监督学习，不依赖有类标号的训练实例

示例：学习阶段

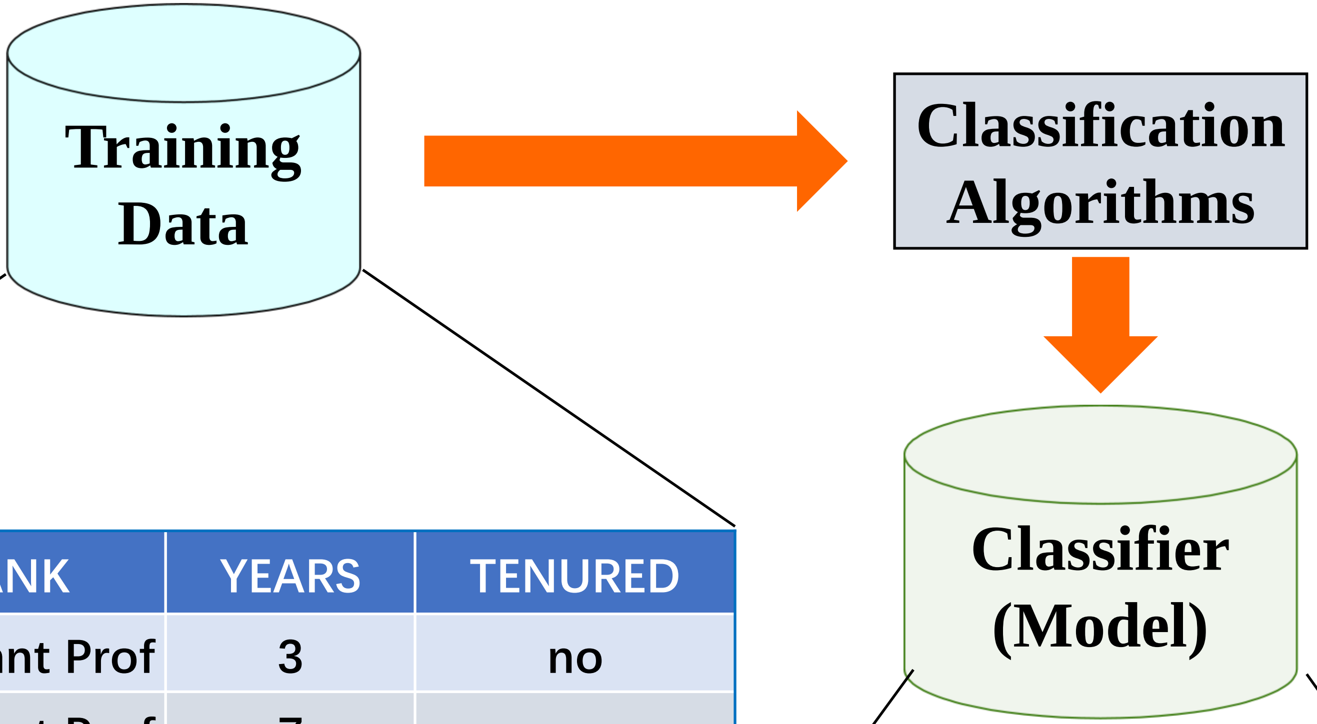

NAME	RANK	YEARS	TENURED
Mike	Assistant Prof	3	no
Mary	Assistant Prof	7	yes
Bill	Professor	2	yes
Jim	Associate Prof	7	yes
Dave	Assistant Prof	6	no
Anne	Associate Prof	3	no

IF rank = ‘professor’
OR years > 6
THEN tenured = ‘yes’

示例：学习阶段

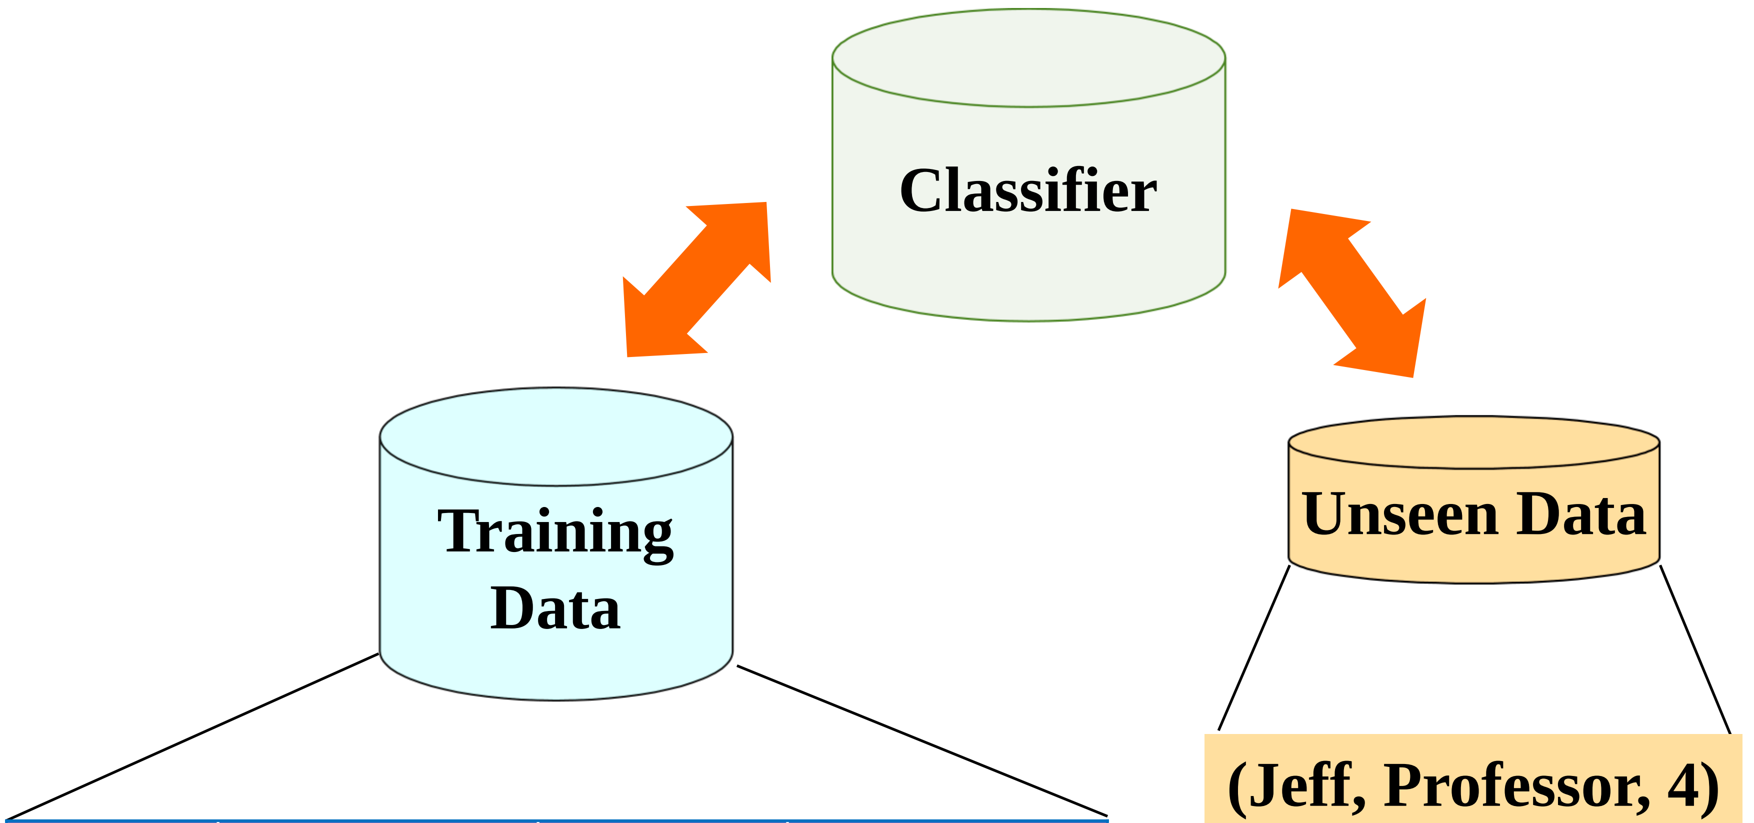

NAME	RANK	YEARS	TENURED
Tom	Assistant Prof	2	no
Merlisa	Associate Prof	7	no
George	Professor	5	yes
Joseph	Assistant Prof	7	yes

南京大學
NANJING UNIVERSITY

目录

朴素贝叶斯分类

- **托马斯·贝叶斯 Thomas Bayes（1701-1761）**
- **An essay towards solving a problem in the doctrine of chances， 1763**

后验　似然　先验

$$\boxed{P(h|D)} = \frac{\boxed{P(D|h)}\boxed{P(h)}}{P(D)}$$

一个例子

- **描述**

一所学校里面有 60% 的男生，40% 的女生。男生总是穿长裤，女生则一半穿长裤一半穿裙子。随机选取一个穿长裤的学生，他（她）是女生的概率是多大?

一个例子

- **描述**

  一所学校里面有 60% 的男生，40% 的女生。男生总是穿长裤，女生则一半穿长裤一半穿裙子。随机选取一个穿长裤的学生，他（她）是女生的概率是多大?

- **形式化**

  已知 P(男生) = 60%，P(女生) = 40%, P(长裤|女生) = 50%, P(长裤|男生) = 100%

  求：P(女生|长裤)

一个例子

- **形式化**

  已知 P(男生) = 60%，P(女生) = 40%, P(长裤|女生) = 50%, P(长裤|男生) = 100%

  求：P(女生|长裤)

- **解答**

$$P(\text{女生}|\text{长裤}) = \frac{P(\text{女生})P(\text{长裤}\,|\,\text{女生})}{P(\text{男生})P(\text{长裤}|\text{男生}) + P(\text{女生})P(\text{长裤}|\text{女生})} = \frac{P(\text{女生})P(\text{长裤}\,|\,\text{女生})}{P(\text{长裤})}$$

- **直观理解**

  算出学校里面有多少穿长裤的，然后在这些人里面再算出有多少女生。

定义

$$P(\text{女生}|\text{长裤}) = \frac{P(\text{长裤}|\text{女生})P(\text{女生})}{P(\text{长裤})}$$

h的似然概率

h的先验概率

$$P(h|D) = \frac{P(D|h)P(h)}{P(D)}$$

h的后验概率

D的先验概率

D：待测试数据
h：假设类别

问题

- **观察知识：**

一所学校里面有 60% 的男生，40% 的女生。男生总是穿长裤，女生则一半穿长裤一半穿裙子。

- **不能够直接观察：**

随机选取一个穿长裤的学生，你倾向于认为学生是男生还是女生？

提出假设

不能够直接观察：随机选取一个穿长裤的学生，你倾向于认为学生是男生还是女生?

- 对于不能直接观察到的部分，往往会提出假设。而对于不确定的事物，往往会有多个假设。

$$P(h|D) = \frac{P(D|h)P(h)}{P(D)}$$

D：待测试数据
h：假设类别

$$P(h_1|D) = \frac{P(D|h_1)P(h_1)}{P(D)}$$

$$P(h_2|D) = \frac{P(D|h_2)P(h_2)}{P(D)}$$

$$P(h_n|D) = \frac{P(D|h_n)P(h_n)}{P(D)}$$

- 对这些假设，往往涉及两个问题：

1. 不同假设的可能性大小?
2. 最合理的假设是什么?

提出假设

不能够直接观察：随机选取一个穿长裤的学生，你倾向于认为学生是男生还是女生?

- **对于不能直接观察到的部分，往往会提出假设。而对于不确定的事物，往往会有多个假设。**

$$P(h|D)=\frac{P(D|h)P(h)}{P(D)}$$

D：待测试数据
h：假设类别

$$P(h_1|D)=\frac{P(D|h_1)P(h_1)}{P(D)}$$

$$P(h_2|D)=\frac{P(D|h_2)P(h_2)}{P(D)}$$

$$P(h_n|D)=\frac{P(D|h_n)P(h_n)}{P(D)}$$

概率分别多大？

- **对这些假设，往往涉及两个问题：**

  1. 不同假设的可能性大小?

  2. 最合理的假设是什么?

提出假设

不能够直接观察：随机选取一个穿长裤的学生，你倾向于认为学生是男生还是女生?

- 对于不能直接观察到的部分，往往会提出假设。而对于不确定的事物，往往会有多个假设。

$$P(h|D) = \frac{P(D|h)P(h)}{P(D)}$$

D：待测试数据
h：假设类别

$$P(h_1|D) = \frac{P(D|h_1)P(h_1)}{P(D)}$$

$$P(h_2|D) = \frac{P(D|h_2)P(h_2)}{P(D)}$$

$$P(h_n|D) = \frac{P(D|h_n)P(h_n)}{P(D)}$$

概率分别多大？

- 对这些假设，往往涉及两个问题：

1. 不同假设的可能性大小?
2. 最合理的假设是什么?

哪个概率更大，则认为D属于哪种类别更合理

极大后验假设

- **极大后验假设定义**
  - **学习器在候选假设集合H中寻找给定数据D时可能性最大的假设h，h被称为极大后验假设（Maximum a posteriori: MAP）**
  - **确定MAP的方法是用贝叶斯公式计算每个候选假设的后验概率，计算式如下**

$$\mathrm{P}(h_1|D)=\frac{P(D|h_1)P(h_1)}{P(D)}$$

$$\mathrm{P}(h_2|D)=\frac{P(D|h_2)P(h_2)}{P(D)}$$

$$\mathrm{P}(h_n|D)=\frac{P(D|h_n)P(h_n)}{P(D)}$$

$$\begin{aligned}\boldsymbol{h_{MAP}} &= \max_{h\in H} \boldsymbol{P(h|D)} \\ &= \max_{h\in H} \mathrm{P}(D|h)\mathrm{P}(h)/P(D) \\ &\boxed{= \max_{h\in H} \mathrm{P}(D|h)\mathrm{P}(h)}\end{aligned}$$

$$\mathrm{P}(h|D)=\frac{\overbrace{P(D|h)}^{\text{h的似然概率}}\overbrace{P(h)}^{\text{h的先验概率}}}{\underbrace{P(D)}_{\text{D的先验概率}}}$$

h的后验概率：$\mathrm{P}(h|D)$

D：待测试数据
h：假设类别

分类中的训练集与测试集

训练集

id	年龄	收入	爱好	信用	购买
1	青	高	否	中	否
2	青	高	否	优	否
3	中	高	否	中	是
4	老	中	否	中	是
5	老	低	是	中	是
6	老	低	是	优	否
7	中	低	是	优	是
8	青	中	否	中	否
9	青	低	是	中	是
10	老	中	是	中	是
11	青	中	是	优	是
12	中	中	否	优	是
13	中	高	是	中	是
14	老	中	否	优	否

测试集

一个收入中等、信用度良好的青年爱好游戏顾客。是否会购买电脑呢?

分类中的训练集与测试集

训练集

id	年龄	收入	爱好	信用	购买
1	青	高	否	中	否
2	青	高	否	优	否
3	中	高	否	中	是
4	老	中	否	中	是
5	老	低	是	中	是
6	老	低	是	优	否
7	中	低	是	优	是
8	青	中	否	中	否
9	青	低	是	中	是
10	老	中	是	中	是
11	青	中	是	优	是
12	中	中	否	优	是
13	中	高	是	中	是
14	老	中	否	优	否

测试集

一个收入中等、信用度良好的青年爱好游戏顾客。

是否会购买电脑呢?

h的似然概率

h的先验概率

$$P(h|D)=\frac{P(D|h)P(h)}{P(D)}$$

D：待测试数据

h：假设类别

h的后验概率

D的先验概率

D待测试数据到底是什么呢?

$$h_{MAP}=\max_{h\in H} P(h|D)$$

$$=\max_{h\in H} P(D|h)P(h)/P(D)$$

$$=\max_{h\in H} P(D|h)P(h)$$

对象是一个多维向量

- 已知：对象D是由多个属性组成的向量
  - $\mathbf{D} = < \mathbf{a}_1, \mathbf{a}_2, \ldots, \mathbf{a}_n >$

一个收入中等、信用度良好的青年爱好游戏顾客。是否会购买电脑呢?

- 目标

$$h_{MAP} = \max_{h \in H} P(h|D) = \max_{h \in H} P(D|h)P(h)/P(D) = \max_{h \in H} P(D|h)P(h)$$

$$h_{MAP} = \max_{h \in H} P(h| < a_1, a_2, \ldots, a_n >) = \max_{h \in H} P(< a_1, a_2, \ldots, a_n > |h)P(h)$$

- 问题
  - 计算$\mathbf{P}(< \mathbf{a}_1, \mathbf{a}_2, \ldots, \mathbf{a}_n > |\mathbf{h})$时，当维度过高时，可用数据变得很稀疏，难以获得结果。

独立性假设

h的似然概率

h的先验概率

$$P(h|D)=\frac{P(D|h)P(h)}{P(D)}$$

h的后验概率

D的先验概率

D：待测试数据
h：假设类别

$$\begin{aligned} h_{MAP} &= \max_{h\in H} P(h|<a_1,a_2,\dots,a_n>) \\ &= \max_{h\in H} P(<a_1,a_2,\dots,a_n>|h)P(h) \end{aligned}$$

- **解决方法**
  - 假设D的属性a_i之间相互独立
  - $\mathbf{P(<a_1,a_2,\dots,a_n>|h)=\prod_i P(a_i|h)}$
  - $$\begin{aligned} \mathbf{h_{MAP}} &= \max_{\mathbf{h\in H}} \mathbf{P(h|<a_1,a_2,\dots,a_n>)} \\ &= \max_{\mathbf{h\in H}} \mathbf{P(<a_1,a_2,\dots,a_n>|h)P(h)} \\ &= \max_{\mathbf{h\in H}} \mathbf{\prod_i P(a_i|h)\,P(h)} \end{aligned}$$
- **优点**
  - 获得估计的$\mathbf{P(a_i|h)}$比$\mathbf{P(<a_1,a_2,\dots,a_n>|h)}$容易很多
  - 如果D的属性之间不满足相互独立，朴素贝叶斯分类的结果是贝叶斯分类的近似

朴素贝叶斯分类案例

训练集

id	年龄	收入	爱好	信用	购买
1	青	高	否	中	否
2	青	高	否	优	否
3	中	高	否	中	是
4	老	中	否	中	是
5	老	低	是	中	是
6	老	低	是	优	否
7	中	低	是	优	是
8	青	中	否	中	否
9	青	低	是	中	是
10	老	中	是	中	是
11	青	中	是	优	是
12	中	中	否	优	是
13	中	高	是	中	是
14	老	中	否	优	否

测试集

一个收入中等、信用度良好的青年爱好游戏顾客。
是否会购买电脑呢?

h的似然概率

h的先验概率

$$P(h|D) = \frac{P(D|h)P(h)}{P(D)}$$

D：待测试数据
h：假设类别

h的后验概率

D的先验概率

$$h_{MAP} = \max_{h\in H} P(h| < a_1, a_2, \dots, a_n >)$$
$$= \max_{h\in H} P(< a_1, a_2, \dots, a_n > |h)P(h)$$

$$h_{MAP} = \max_{h\in H} P(h| < a_1, a_2, \dots, a_n >)$$
$$= \max_{h\in H} P(< a_1, a_2, \dots, a_n > |h)P(h)$$
$$= \max_{h\in H} \prod_i P(a_i|h)\, P(h)$$

朴素贝叶斯分类案例

一个收入中等、信用度良好的青年爱好游戏顾客。

id	年龄段	收入状况	爱好	信用度	购买电脑
3	中	高	否	中	是
4	老	中	否	中	是
5	老	低	是	中	是
7	中	低	是	优	是
9	青	低	是	中	是
10	老	中	是	中	是
11	青	中	是	优	是
12	中	中	否	优	是
13	中	高	是	中	是

P(青年 |购买) = 2/9 = 0.222

P(收入中等 |购买) = 4/9 = 0.444

P(爱好 |购买) = 6/9 = 0.667

P(信用中 | 购买) =6/9 = 0.667

$$P(\mathbf{X}|C_i) = \prod_{k=1}^{n} P(x_k|C_i) = P(x_1|C_i) \times P(x_2|C_i) \times \ldots \times P(x_n|C_i)$$

P(X | 购买) = 0.222 ×0.444 ×0.667 ×0.667=0.044

朴素贝叶斯分类案例

一个收入中等、信用度良好的青年爱好游戏顾客。

id	年龄段	收入状况	爱好	信用度	购买电脑
1	青	高	否	中	否
2	青	高	否	优	否
6	老	低	是	优	否
8	青	中	否	中	否
14	老	中	否	优	否

P(青年 |不买) = 3/5 = 0.6

P(收入中等 |不买) = 2/5 = 0.4

P(爱好 |不买) = 1/5 = 0.2

P(信用中 |不买) = 2/5 = 0.4

$$P(\mathbf{X}|C_i) = \prod_{k=1}^{n} P(x_k|C_i) = P(x_1|C_i) \times P(x_2|C_i) \times \ldots \times P(x_n|C_i)$$

P(X |不买) =0.6 ×0.4 ×0.2 ×0.4=0.019

朴素贝叶斯分类案例

一个收入中等、信用度良好的青年爱好游戏顾客。

id	年龄	收入	爱好	信用	购买
1	青	高	否	中	否
2	青	高	否	优	否
3	中	高	否	中	是
4	老	中	否	中	是
5	老	低	是	中	是
6	老	低	是	优	否
7	中	低	是	优	是
8	青	中	否	中	否
9	青	低	是	中	是
10	老	中	是	中	是
11	青	中	是	优	是
12	中	中	否	优	是
13	中	高	是	中	是
14	老	中	否	优	否

$$h_{MAP} = \max_{h \in H} P(h| < a_1, a_2, \ldots, a_n >)$$
$$= \max_{h \in H} P(< a_1, a_2, \ldots, a_n > |h) P(h)$$
$$= \max_{h \in H} \prod_i P(a_i|h)\, P(h)$$

$$P(\mathbf{X}|C_i)P(C_i)$$

$P(C_{购买})$ =9/14=0.643

$P(C_{不买})$ =5/14=0.357

P(购买|X) =0.044×0.643=0.028

P(不买|X) = 0.019 ×0.357=0.007

一个例子

- **问题**
  - 给定一封邮件，判定它是否属于垃圾邮件。按照先例，用 D 来表示邮件（注意 D 由 n个单词的属性合取$< a_1, a_2, \dots, a_n >$组成）。用 h+ 来表示垃圾邮件，h-表示正常邮件,即目标空间H=<h+,h->。
- **形式化描述:**
  - $P(h+|D) = P(h+) * P(D|h+)/P(D)$
  - $P(h-|D) = P(h-) * P(D|h-)/P(D)$


发件人: [redacted]
收件人: #公司全员
抄送:
主题: 厚积薄发、NEC手机王者归来——旗舰产品NEC 909e内部促销

邮件 | NEC909e内部促销登记表.xlsx (13 KB) | NEC手机内销方案.pdf (2 MB)

配送方式:
北京、上海、广州地区的同事:
货到付款，现金支付，发票在收到货款后的15日内出具（提供普通发票，发票抬头只能填写付款人的姓名）。
北京、上海、广州以外地区的同事:
请将手机款打入指定账户，收到付款后，通过邮寄的方式配送货品和发票。

联系方式:
移动終端事业部
联系人: [redacted]
电话: [redacted]
邮箱: [redacted]

移动終端事业部是一个新成立的事业部，全面负责日本 NEC 卡西欧移动通信株式会社 NEC 品牌手机在中国大陆地区的市场运营，以后还请大家多多关照。

十分感谢各位的支持。

移动終端事业部
2012 年 3 月 9 日

Thanks & Best Regards
※※※※※※※※※※※※※※※※※※※※※※※※※※※

一个例子

- **求解**$\mathrm{P}(\mathrm{h}+|D)=\mathrm{P}(\mathrm{h}+)*\mathrm{P}(\mathrm{D}|\mathrm{h}+)/\mathrm{P}(\mathrm{D})$
- $\mathrm{P}(\mathrm{h}+)$
  - 即计算已有训练集合中垃圾邮件的比例


发件人: [redacted]
收件人: #公司全员
抄送:
主题: 厚积薄发、NEC手机王者归来——旗舰产品NEC 909e内部促销

邮件 | NEC909e内部促销登记表.xlsx (13 KB) NEC手机内销方案.pdf (2 MB)

配送方式：
北京、上海、广州地区的同事：
货到付款，现金支付，发票在收到货款后的15日内出具（提供普通发票，发票抬头只能填写付款人的姓名）。
北京、上海、广州以外地区的同事：
请将手机款打入指定账户，收到付款后，通过邮寄的方式配送货品和发票。

联系方式：
移动终端事业部
联系人：[redacted]
电话：[redacted]
邮箱：[redacted]

移动终端事业部是一个新成立的事业部，全面负责日本NEC卡西欧移动通信株式会社NEC品牌手机在中国大陆地区的市场运营，以后还请大家多多关照。

十分感谢各位的支持。

移动终端事业部
2012年3月9日

Thanks & Best Regards
※※※※※※※※※※※※※※※※※※※※※※※※※※※※※※

一个例子

发件人: [redacted]
收件人: #公司全员
抄送:
主题: 厚积薄发、NEC手机王者归来——旗舰产品NEC 909e内部促销
邮件 | NEC909e内部促销登记表.xlsx (13 KB) NEC手机内销方案.pdf (2 MB)

配送方式:
北京、上海、广州地区的同事:
货到付款，现金支付，发票在收到货款后的15日内出具（提供普通发票，发票抬头只能填写付款人的姓名）。
北京、上海、广州以外地区的同事:
请将手机款打入指定账户，收到付款后，通过邮寄的方式配送货品和发票。

联系方式:
移动终端事业部
联系人: [redacted]
电话: [redacted]
邮箱: [redacted]

移动终端事业部是一个新成立的事业部，全面负责日本NEC卡西欧移动通信株式会社NEC品牌手机在中国大陆地区的市场运营，以后还请大家多多关照。

十分感谢各位的支持。

移动终端事业部
2012年3月9日

Thanks & Best Regards

- **求解**$\mathrm{P}(\mathrm{h}+|D)=\mathrm{P}(\mathrm{h}+)*\mathrm{P}(\mathrm{D}|\mathrm{h}+)/\mathrm{P}(\mathrm{D})$
- $\mathrm{P}(\mathrm{h}+)$
  - 即计算已有训练集合中垃圾邮件的比例
- $\mathrm{P}(D|\mathrm{h}+)=\mathrm{P}(<a_1,a_2,\ldots,a_n>|\mathrm{h}+)$
  - 即计算垃圾邮件中完全包含$a_1,a_2,\ldots,a_n$这n个单词的邮件比例。当n很大时，这几乎不可能。
  - 利用朴素贝叶斯$\mathrm{P}(<a_1,a_2,\ldots,a_n>|\mathrm{h}+)=\prod_{\mathrm{i}}\mathrm{P}(a_i|\mathrm{h}+)$，对于每个$\mathrm{P}(a_i|\mathrm{h}+)$，就是要求解单词$a_i$在垃圾邮件训练集合中出现的频率。

一个例子

- **求解**$\mathrm{P}(\mathrm{h}+|D)=\mathrm{P}(\mathrm{h}+)*\mathrm{P}(\mathrm{D}|\mathrm{h}+)/\mathrm{P}(\mathrm{D})$
- $\mathrm{P}(\mathrm{h}+)$
  - 即计算已有训练集合中垃圾邮件的比例
- $\mathrm{P}(D|\mathrm{h}+)=\mathrm{P}(<a_1,a_2,\dots,a_n>|\mathrm{h}+)$
  - 即计算垃圾邮件中完全包含$a_1,a_2,\dots,a_n$这n个单词的邮件比例。当n很大时，这几乎不可能。
  - 利用朴素贝叶斯$\mathrm{P}(<a_1,a_2,\dots,a_n>|\mathrm{h}+)=\prod_{\mathrm{i}}\mathrm{P}(a_i|\mathrm{h}+)$，对于每个$\mathrm{P}(a_i|\mathrm{h}+)$，就是要求解单词$a_i$在垃圾邮件训练集合中出现的频率。
- **P(D)即单词$a_1,a_2,\dots,a_n$同时出现在一封邮件中的概率，可假设为常量。**


发件人: [redacted]
收件人: #公司全员
抄送:
主题: 厚积薄发、NEC手机王者归来——旗舰产品NEC 909e内部促销

邮件 | NEC909e内部促销登记表.xlsx (13 KB) | NEC手机内销方案.pdf (2 MB)

配送方式：
北京、上海、广州地区的同事：
货到付款，现金支付，发票在收到货款后的15日内出具（提供普通发票，发票抬头只能填写付款人的姓名）。
北京、上海、广州以外地区的同事：
请将手机款打入指定账户，收到付款后，通过邮寄的方式配送货品和发票。

联系方式：
移动終端事业部
联系人：[redacted]
电话：[redacted]
邮箱：[redacted]

移动終端事业部是一个新成立的事业部，全面负责日本NEC卡西欧移动通信株式会社NEC品牌手机在中国大陆地区的市场运营，以后还请大家多多关照。

十分感谢各位的支持。

移动終端事业部
2012年3月9日

Thanks & Best Regards

一个例子

- **求解**$\mathrm{P}(\mathrm{h}+|D)=\mathrm{P}(\mathrm{h}+)*\mathrm{P}(\mathrm{D}|\mathrm{h}+)/\mathrm{P}(\mathrm{D})$
- $\mathrm{P}(\mathrm{h}+)$
  - 即计算已有训练集合中垃圾邮件的比例
- $\mathrm{P}(D|\mathrm{h}+)=\mathrm{P}(<a_1,a_2,\ldots,a_n>|\mathrm{h}+)$
  - 即计算垃圾邮件中完全包含$a_1,a_2,\ldots,a_n$这n个单词的邮件比例。当n很大时，这几乎不可能。
  - 利用朴素贝叶斯$\mathrm{P}(<a_1,a_2,\ldots,a_n>|\mathrm{h}+)=\prod_{\mathrm{i}}\mathrm{P}(a_i|\mathrm{h}+)$，对于每个$\mathrm{P}(a_i|\mathrm{h}+)$，就是要求解单词$a_i$在垃圾邮件训练集合中出现的频率。
- **$\mathrm{P}(\mathrm{D})$即单词$a_1,a_2,\ldots,a_n$同时出现在一封邮件中的概率，可假设为常量。**
- **同理求解**$\mathrm{P}(\mathrm{h}-|D)=\mathrm{P}(\mathrm{h}-)*\mathrm{P}(\mathrm{D}|\mathrm{h}-)/\mathrm{P}(\mathrm{D})$
- **比较**$\mathrm{P}(\mathrm{h}+|D)$**和**$\mathrm{P}(\mathrm{h}-|D)$**的大小**

一个例子

$$P(h+|D)=P(h+)*P(D|h+)/P(D)$$

- **已知**
  - 训练集合中垃圾邮件的比例为$\mathbf{P(h+)=0.2}$
  - 训练集合中正常邮件的比例为$\mathbf{P(h-)=0.8}$
  - 单词出现频率表

分词	在垃圾邮件中出现的比例	在正常邮件中出现的比例
免费	0.3	0.01
奖励	0.2	0.01
网站	0.2	0.2

- **求解**
  - 判断一封邮件D=<“免费”,”奖励”，“网站”>是否是垃圾邮件

一个例子

$$P(h+|D) = P(h+) * P(D|h+)/P(D)$$

$$\boldsymbol{P(h+|D) = P(h+) * \frac{P(D|h+)}{P(D)}}$$

$$\boldsymbol{= 0.2 * \frac{(0.3*0.2*0.2)}{P(D)} = 0.0096/P(D)}$$

$$\boldsymbol{P(h-|D) = P(h-) * \frac{P(D|h-)}{P(D)}}$$

$$\boldsymbol{= 0.8 * \frac{(0.01*0.01*0.2)}{P(D)} = 0.000016/P(D)}$$

$$\boldsymbol{P(h+|D) > \mathrm{P(h-|D)}}$$

朴素贝叶斯分类 —— 连续数据如何求概率

id	年龄	收入	爱好	信用	购买
1	青	高	否	中	否
2	青	高	否	优	否
3	中	低	否	中	否
4	老	高	否	中	否
5	老	中	是	中	是
6	老	低	是	优	否
7	中	高	是	优	否
8	青	中	否	中	是
9	青	低	是	中	否
10	老	中	是	中	是

id	年龄	收入	爱好	信用	购买
1	青	125	否	中	否
2	青	100	否	优	否
3	中	70	否	中	否
4	老	120	否	中	否
5	老	95	是	中	是
6	老	60	是	优	否
7	中	220	是	优	否
8	青	85	否	中	是
9	青	75	是	中	否
10	老	90	是	中	是

预测收入为121，无游戏爱好、信用良好的中年人，是否购买

朴素贝叶斯分类 —— 连续数据如何求概率

id	收入	购买
1	125	否
2	100	否
3	70	否
4	120	否
5	95	是
6	60	否
7	220	否
8	85	是
9	75	否
10	90	是

假设不同类别收入分别服从不同正态分布

$$P(X_i|c_{ij}) = \frac{1}{\sqrt{2\pi\sigma_{ij}^2}} e^{-\frac{(x_i-\mu_{ij})^2}{2\sigma_{ij}^2}}$$

利用参数估计两组正态分布期望和方差

朴素贝叶斯分类 —— 连续数据如何求概率

id	收入	购买
1	125	否
2	100	否
3	70	否
4	120	否
5	95	是
6	60	否
7	220	否
8	85	是
9	75	否
10	90	是

假设不同类别收入分别服从不同正态分布

$$P(X_i|c_{ij}) = \frac{1}{\sqrt{2\pi\sigma_{ij}^2}} e^{-\frac{(x_i-\mu_{ij})^2}{2\sigma_{ij}^2}}$$

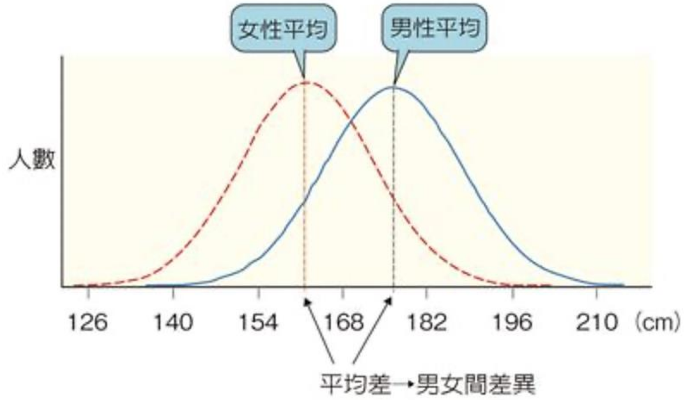

利用参数估计两组正态分布期望和方差

$$P(收入 = 121|No) = \frac{1}{\sqrt{2\pi}(54.54)} e^{-\frac{(121-110)^2}{2(2975)}}$$

$$= 0.0072$$

贝叶斯分类器总结

- **本质上是同时考虑了先验概率和似然概率的重要性**
- **特点**
  - 属性可以离散、也可以连续
  - 数学基础坚实、分类效率稳定
  - 对缺失和噪声数据不太敏感
  - 属性如果不相关，分类效果很好

参考文献

- 数学之美番外篇：平凡而又神奇的贝叶斯方法. 网络文章.
- 贝叶斯学派与频率学派有何不同?

  http://www.zhihu.com/question/20587681/answer/16023547

贝叶斯分类编程实践

https://scikit-learn.org/stable/modules/generated/sklearn.naive_bayes.GaussianNB.html#sklearn.naive_bayes.GaussianNB

https://scikit-learn.org/stable/modules/generated/sklearn.naive_bayes.MultinomialNB.html#sklearn.naive_bayes.MultinomialNB

https://scikit-learn.org/stable/modules/generated/sklearn.naive_bayes.ComplementNB.html#sklearn.naive_bayes.ComplementNB

https://scikit-learn.org/stable/modules/generated/sklearn.naive_bayes.BernoulliNB.html#sklearn.naive_bayes.BernoulliNB

https://scikit-learn.org/stable/modules/generated/sklearn.naive_bayes.BernoulliNB.html#sklearn.naive_bayes.BernoulliNB

同学们可以尝试利用python读入本地iris数据集，来完成贝叶斯分类，分析其分类效果

贝叶斯分类编程实践

- Iris数据集中包含了: 山鸢尾(Setosa), 杂色鸢尾(Versicolour), 维吉尼亚鸢尾(Virginica), 每种50个数据, 共含150个数据。
- 在每个数据包含四个属性:
  - ✓ 花萼长度(sepal length in cm),
  - ✓ 花萼宽度(sepal width in cm),
  - ✓ 花瓣长度(petal length in cm),
  - ✓ 花瓣宽度(petal width in cm)
- 可通过这四个属性预测鸢尾花卉属于 (山鸢尾, 杂色鸢尾, 维吉尼亚鸢尾) 哪一类。

数据集中部分数据如右图所示:

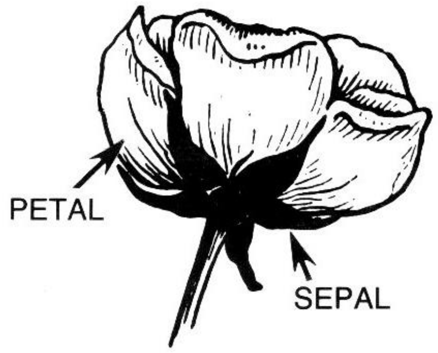

IRIS（sepal:萼片, petal:花瓣）

```
6.7,3.0,5.2,2.3,Iris-virginica
6.3,2.5,5.0,1.9,Iris-virginica
6.5,3.0,5.2,2.0,Iris-virginica
6.2,3.4,5.4,2.3,Iris-virginica
5.9,3.0,5.1,1.8,Iris-virginica
5.1,3.8,1.6,0.2,Iris-setosa
4.6,3.2,1.4,0.2,Iris-setosa
5.3,3.7,1.5,0.2,Iris-setosa
5.0,3.3,1.4,0.2,Iris-setosa
7.0,3.2,4.7,1.4,Iris-versicolor
6.4,3.2,4.5,1.5,Iris-versicolor
6.9,3.1,4.9,1.5,Iris-versicolor
5.5,2.3,4.0,1.3,Iris-versicolor
```

参考资料：https://www.kaggle.com/datasets/uciml/iris

贝叶斯分类编程实践

具体要求

- 建议使用scikit-learn中的load_iris函数载入数据集，如使用本地数据集，文件路径设置为“./iris.csv”（即当前代码文件路径下）。
- 对数据进行预处理，如缺失值处理、数据标准化等。
- 利用Python实现朴素贝叶斯分类器。推荐使用scikit-learn库中的相关函数，但鼓励自己编写核心逻辑以加深理解。
- 将数据集分为训练集和测试集，比例自定，至少保持70%的数据用于训练。
- 训练模型并对测试集进行预测。
- 计算模型的准确率（需不低于95%）等评价指标。
- 可选：尝试调整参数或采用不同的特征选择方法来提高模型性能。

贝叶斯分类编程实践

上交形式

- 提交完整的代码文件（使用Jupyter Notebook格式）。
- 文件命名为“学号-姓名-准确率.ipynb”（如602024710021-张三-97.ipynb）。

注意事项

- 确保代码具有良好的可读性，适当添加注释说明。
- 遵守学术诚信原则，严禁抄袭他人作品。