

Ch05: 多维随机变量及其数字特征

# **Numerical Characteristics of Multi-dimensional Random Vectors**

November 20, 2023

## 回顾：多维正态分布的标准化

Focus: 设  $n$  维随机向量  $X = (X_1, X_2, \dots, X_n) \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ , 以及正定矩阵  $\boldsymbol{\Sigma}$  的特征值分解  $\boldsymbol{\Sigma} = \boldsymbol{U}^\top \boldsymbol{\Lambda} \boldsymbol{U}$ , 则随机向量

$$Y = \boldsymbol{\Lambda}^{-1/2} \boldsymbol{U} (X - \boldsymbol{\mu}) \sim \mathcal{N}(\mathbf{0}_n, \boldsymbol{I}_n) .$$

我们需要明确两件事情:

- $\mathcal{N}(\mathbf{0}_n, \boldsymbol{I}_n)$  的分量之间是独立的. 进一步, 当  $\boldsymbol{\Sigma}$  为对角阵的时候, 多元正态分布的随机变量之间是独立的.
- $\boldsymbol{\Lambda}^{-1/2} \boldsymbol{U} (X - \boldsymbol{\mu})$  所带来的线性变换可以将  $X$  标准化.

## 线性运算的基本性质

- 回忆: 矩阵的特征值和特征向量. 以二维为例, 矩阵  $\mathbf{A}$  拥有特征值  $\Lambda_1$  和  $\Lambda_2$ , 分别对应特征向量  $\mathbf{u}_1, \mathbf{u}_2$ . 则有

$$\mathbf{A}\mathbf{u}_i = \Lambda_i\mathbf{u}_i, \quad i = 1, 2$$

进而有  $\mathbf{A} = \mathbf{U}^\top \mathbf{\Lambda} \mathbf{U}$  with  $\mathbf{U}^\top = \mathbf{U}^{-1}$ , 即

$$\begin{pmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{pmatrix} = \begin{pmatrix} u_{11} & u_{21} \\ u_{12} & u_{22} \end{pmatrix} \begin{pmatrix} \Lambda_1 & 0 \\ 0 & \Lambda_2 \end{pmatrix} \begin{pmatrix} u_{11} & u_{12} \\ u_{21} & u_{22} \end{pmatrix}$$

- 几何性质. For the case of  $\mathbf{A}\mathbf{v}$  given any  $\mathbf{v}$ ,
  - 矩阵  $\mathbf{U}$  负责对  $\mathbf{v}$  进行旋转
  - 矩阵  $\mathbf{\Lambda}$  负责对  $\mathbf{v}$  进行放缩

# 线性运算的基本性质

举个栗子,  $\mathbf{A} = [1, 2; 2, 1]$

- 求特征值.  $|\mathbf{\Lambda I} - \mathbf{A}| = 0$ , 得  $\mathbf{\Lambda}_1 = -1$  和  $\mathbf{\Lambda}_2 = 3$ .

- 求特征向量. 当  $\mathbf{\Lambda}_1 = -1$  时,

$$(\mathbf{\Lambda}_i \mathbf{I} - \mathbf{A})\mathbf{u}_1 = \begin{pmatrix} -2 & -2 \\ -2 & -2 \end{pmatrix} \begin{pmatrix} u_{11} \\ u_{12} \end{pmatrix}$$

所以,  $\mathbf{u}_1 = (1/\sqrt{2}, -1/\sqrt{2})$ . 同理, 有  $\mathbf{u}_2 = (1/\sqrt{2}, 1/\sqrt{2})$ .

- 根据  $\mathbf{UA} = \mathbf{\Lambda U}$ , 可理解为

- 正交坐标轴  $\mathbf{U}$  上的向量 = 正交坐标轴  $\mathbf{U}$  的线性组合

- 协交坐标轴  $\mathbf{A}$  上的向量 = 协交坐标轴  $\mathbf{A}$  的线性组合

- For the case of  $\mathbf{Av}$ ,  $\mathbf{Uv}$  实现了对  $\mathbf{v}$  的旋转, 而  $\mathbf{\Lambda}$  实现了对  $|\mathbf{v}|$  的放缩.

为了授课方便, 这里只关心对称的方阵. 同理, 可以推至非方阵的情况.

## 线性运算的基本性质

如果我们面对一个运算  $\mathbf{A}\mathbf{x} + \mathbf{b}$ ,

- $\mathbf{b}$  是平移
- $\mathbf{U}$  是旋转, if  $|\mathbf{U}| = 1$
- $\mathbf{\Lambda}$  是放缩, as  $|\mathbf{A}\mathbf{x}| = |\mathbf{\Lambda}\mathbf{x}|$

面对  $\mathbf{Y} = \mathbf{\Lambda}^{-1/2}\mathbf{U}(\mathbf{X} - \boldsymbol{\mu}) = \boldsymbol{\Sigma}^{-1/2}(\mathbf{X} - \boldsymbol{\mu})$

- $-\boldsymbol{\mu}$  或者  $-\boldsymbol{\Sigma}^{-1/2}\boldsymbol{\mu}$  是平移, 使得  $\mathbf{X} - \mathbf{u}$  以原点为中心 ( $\mathbf{X}$  以  $\mathbf{u}$  为中心)
- $\mathbf{U}$  是旋转
- $\mathbf{\Lambda}^{-1/2}$  是放缩, 尤其是在  $\mathbf{\Lambda}^{-1/2}\bar{\mathbf{X}}$  的情形下

## 线性变换可以将 $X$ 标准化

我们有

$$(\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) = \mathbf{y}^\top \mathbf{y} = \mathbf{y}^\top \mathbf{I}_n \mathbf{y}$$

• 一方面,

$$\bar{\mathbf{x}}^\top \boldsymbol{\Sigma}^{-1} \bar{\mathbf{x}} = \bar{\mathbf{x}}^\top \mathbf{U} \boldsymbol{\Lambda}^{-1} \mathbf{U}^\top \bar{\mathbf{x}} = (\mathbf{U}^\top \bar{\mathbf{x}})^\top \boldsymbol{\Lambda}^{-1} (\mathbf{U}^\top \bar{\mathbf{x}})$$

• 另一方面,

$$|\boldsymbol{\Sigma}^{-1/2} \bar{X}| = |\boldsymbol{\Lambda}^{-1/2} \bar{X}| = |Y|$$

所以,

$$\begin{aligned} |\bar{\mathbf{x}}^\top \boldsymbol{\Sigma}^{-1} \bar{\mathbf{x}}| &= |(\mathbf{U}^\top \bar{\mathbf{x}})^\top \boldsymbol{\Lambda}^{-1} (\mathbf{U}^\top \bar{\mathbf{x}})| \\ &= |(\mathbf{U}^\top \bar{\mathbf{x}})^\top| |\boldsymbol{\Lambda}^{-1}| |(\mathbf{U}^\top \bar{\mathbf{x}})| \\ &= |\mathbf{x}^\top| |\boldsymbol{\Lambda}^{-1}| |\mathbf{x}| \\ &= |\mathbf{y}^\top| |\mathbf{y}| \end{aligned}$$

线性变换可以将  $X$  标准化

根据

$$f(\boldsymbol{x}) = (2\pi)^{-n/2} |\boldsymbol{\Sigma}|^{-1/2} \exp \left( -(\boldsymbol{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\boldsymbol{x} - \boldsymbol{\mu}) / 2 \right)$$

和

$$\boldsymbol{Y} = \boldsymbol{\Lambda}^{-1/2} \boldsymbol{U} (\boldsymbol{X} - \boldsymbol{\mu})$$

有

$$f_Y(\boldsymbol{y}) = (2\pi)^{-n/2} \exp \left( -\boldsymbol{y}^\top \boldsymbol{y} / 2 \right)$$

## 对角的协方差矩阵对应独立性

求证: 当  $\Sigma$  为对角阵的时候, 多元正态分布的随机变量之间是独立的.

回顾: 多维正态分布的密度函数

$$f(\mathbf{x}) = (2\pi)^{-n/2} |\Sigma|^{-1/2} \exp \left( -(\mathbf{x} - \boldsymbol{\mu})^\top \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}) / 2 \right)$$

如果  $\Sigma$  为对角阵, 假设为  $\Sigma^{-1} = \text{Diag}\{\lambda_1^{-1}, \dots, \lambda_n^{-1}\}$ . 则指数项可以拆解为

$$\frac{-1}{2} [\lambda_1^{-1}(\bar{x}_1)^2 + \dots + \lambda_n^{-1}(\bar{x}_n)^2]$$

进而有

$$\begin{aligned} f(\mathbf{x}) &= (2\pi)^{-n/2} \left( \prod_{i=1}^n \lambda_i^{-1/2} \right) \exp \left( \frac{-1}{2} [\lambda_1^{-1}(\bar{x}_1)^2 + \dots + \lambda_n^{-1}(\bar{x}_n)^2] \right) \\ &= \prod_{i=1}^n \left( \frac{1}{\sqrt{2\pi} \sqrt{\lambda_i}} \right) \exp \left[ -\frac{(\bar{x}_1)^2}{2\lambda_1} - \dots - \frac{(\bar{x}_n)^2}{2\lambda_n} \right] \end{aligned}$$



## 对角的协方差矩阵对应着独立性

重新整理

$$\begin{aligned} f(\mathbf{x}) &= (2\pi)^{-n/2} \left( \prod_{i=1}^n \lambda_i^{-1/2} \right) \exp \left( \frac{-1}{2} [\lambda_1^{-1}(\bar{x}_1)^2 + \cdots + \lambda_n^{-1}(\bar{x}_n)^2] \right) \\ &= \prod_{i=1}^n \left( \frac{1}{\sqrt{2\pi}\sqrt{\lambda_i}} \right) \exp \left[ -\frac{(\bar{x}_1)^2}{2\lambda_1} - \cdots - \frac{(\bar{x}_n)^2}{2\lambda_n} \right] \\ &= \prod_{i=1}^n \left( \frac{1}{\sqrt{2\pi}\sqrt{\lambda_i}} \exp \left( -\frac{(\bar{x}_i)^2}{2\lambda_i} \right) \right) \end{aligned}$$

因此, 有

$$f(\mathbf{x}) = \prod_{i=1}^n f_{X_i}(x_i)$$

## 基于上述运算, 我们可以推导多维正态分布其他性质 – 证明已留作思考题

设随机向量  $X = (X_1, X_2, \dots, X_n)^\top$  和  $Y = (Y_1, Y_2, \dots, Y_m)^\top$ , 以及

$$\begin{pmatrix} X \\ Y \end{pmatrix} \sim \mathcal{N} \left( \begin{pmatrix} \mu_x \\ \mu_y \end{pmatrix}, \begin{pmatrix} \Sigma_{xx} & \Sigma_{xy} \\ \Sigma_{yx} & \Sigma_{yy} \end{pmatrix} \right),$$

则有

- 随机向量  $X$  和  $Y$  的边缘分布为  $X \sim \mathcal{N}(\mu_x, \Sigma_{xx})$  和  $Y \sim \mathcal{N}(\mu_y, \Sigma_{yy})$
- 随机向量  $X$  和  $Y$  相互独立的充要条件是  $\Sigma_{xy} = \mathbf{0}_{m \times n}$  (元素全为零的  $m \times n$  矩阵)
- 在  $X = \mathbf{x}$  的条件下, 随机向量  $Y$  的分布

$$Y \mid X = \mathbf{x} \sim \mathcal{N}(\mu_y + \Sigma_{yx} \Sigma_{xx}^{-1}(\mathbf{x} - \mu_x), \Sigma_{yy} - \Sigma_{yx} \Sigma_{xx}^{-1} \Sigma_{xy})$$

- 在  $Y = \mathbf{y}$  的条件下, 随机向量  $X$  的分布

$$X \mid Y = \mathbf{y} \sim \mathcal{N}(\mu_x + \Sigma_{xy} \Sigma_{yy}^{-1}(\mathbf{y} - \mu_y), \Sigma_{xx} - \Sigma_{xy} \Sigma_{yy}^{-1} \Sigma_{yx})$$

# 数字特征的引言

类似于一维随机变量的数字特征, 多维随机变量也有数字特征

- 一方面是各分量自己的数字特征, 比如: 期望、方差、标准差等
- 另一方面是分量之间的关联程度, 反映随机变量间相依关系的数字特征, 即协方差与相关系数.

## 多维随机向量函数的期望

定义 **0.54** [Informally, 期望 = < 取值, 概率 >]

离散随机变量  $(X, Y)$  的分布列为  $p_{ij} = P(X = x_i, Y = y_j)$ , 则随机变量  $Z = g(X, Y)$  的期望为

$$\mathbb{E}[Z] = \mathbb{E}[g(X, Y)] = \sum_{i,j} g(x_i, y_j) p_{ij}.$$

连续随机变量  $(X, Y)$  的概率密度为  $f(x, y)$ , 则随机变量  $Z = g(X, Y)$  的期望为

$$\mathbb{E}[Z] = \mathbb{E}[g(X, Y)] = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} g(x, y) f(x, y) dx dy.$$

# 期望的性质

- 若随机向量  $X \geq Y$ , 则  $\mathbb{E}[X] \geq \mathbb{E}[Y]$ ;
- **线性性**. 对任意随机向量  $X$  和  $Y$ , 有  $\mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y]$ ;
- 对任意随机向量  $X$  和  $Y$ , 有 Cauchy-Schwartz 不等式:

$$|\mathbb{E}[XY]| \leq \sqrt{\mathbb{E}[X^2]\mathbb{E}[Y^2]}$$

- **独立可乘**. 若随机变量  $X$  与  $Y$  相互独立, 有  $\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$ ;
- **独立方差**. 若随机变量  $X$  与  $Y$  相互独立, 有  $\text{VAR}(X + Y) = \text{VAR}(X) + \text{VAR}(Y)$ .

## 多维随机向量函数的期望：例 0.96

**例 0.96** 设随机变量  $X$  与  $Y$  相互独立且都服从标准正态分布  $\mathcal{N}(0, 1)$ , 求  $\mathbb{E}[\max(X, Y)]$ .

## 解答：例 0.96

题目：设随机变量  $X$  与  $Y$  相互独立且都服从标准正态分布  $\mathcal{N}(0, 1)$ , 求  $\mathbb{E}[\max(X, Y)]$ .

解答：

- 由题易知  $X$  与  $Y$  的联合密度函数为

$$f(x, y) = f_X(x)f_Y(y) = \frac{1}{2\pi}e^{-\frac{x^2+y^2}{2}}.$$

- 将二维平面区域分为两部分  $D_1 = \{(x, y) : x \geq y\}$ ,  $D_2 = \{(x, y) : x < y\}$ , 于是得到

$$\begin{aligned}\mathbb{E}[\max(X, Y)] &= \int \int_{D_1} x f(x, y) dx dy + \int \int_{D_2} y f(x, y) dx dy \\&= \int_{-\infty}^{+\infty} dy \int_y^{+\infty} x f(x, y) dx + \int_{-\infty}^{+\infty} dx \int_x^{+\infty} y f(x, y) dy \\&= 2 \int_{-\infty}^{+\infty} dy \int_y^{+\infty} x f(x, y) dx = \frac{1}{\pi} \int_{-\infty}^{+\infty} dy \int_y^{+\infty} x e^{-\frac{x^2+y^2}{2}} dx \\&= \frac{1}{\pi} \int_{-\infty}^{+\infty} e^{-y^2} dy = \frac{1}{\sqrt{\pi}}\end{aligned}$$

## 多维随机向量函数的期望：例 0.97

**例 0.97** 某水果超市在每星期一进货一定数量的新鲜水果, 假设一周内出售水果的件数  $X \sim U(10, 20)$ . 若这一周内出售一件水果获利 10 元, 若不能出售则因为水果过期而每件亏损 4 元, 求水果超市的最优进货策略.



## 解答：例 0.97

题目：如上所述.

解答：

- 不妨设水果超市每周进货  $n$  件 ( $10 \leq n \leq 20$ ), 则它的周利润为

$$Y = \begin{cases} 10n, & X \geq n \\ 10X - 4(n - X), & X < n \end{cases}$$

- 周利润  $Y$  是关于  $X$  的随机变量, 考虑在期望下的最优策略

$$\begin{aligned} \mathbb{E}[Y] &= \sum_{i=10}^{n-1} (10i - 4(n - i))P(X = i) + \sum_{i=n}^{20} 10nP(X = i) \\ &= \sum_{i=10}^{n-1} \frac{14i - 4n}{10} + \sum_{i=n}^{20} n = \frac{-7n^2 + 243n + 630}{10}. \end{aligned}$$

上式对  $n$  求导并令导数为零, 求解可得  $n = 17.36$ . 则  $n$  可能取 17 或者 18, 经验证, 最后取  $n = 17$ .

## 多维随机向量函数的条件期望

回顾: 对二维随机向量  $(X, Y)$  而言, 随机变量  $X$  的条件分布, 即给定随机变量  $Y$  取值的条件下  $X$  的概率分布. 而条件期望是条件分布的数学期望, 具体定义如下:

**定义 0.55** 设  $(X, Y)$  为离散型随机向量, 在  $Y = y$  的条件下  $X$  的条件分布列为  $P(X = x_i | Y = y)$ , 称

$$\mathbb{E}(X|y) = \mathbb{E}(X|Y = y) = \sum_i x_i P(X = x_i | Y = y)$$

为在  $Y = y$  的条件下  $X$  的**条件期望**. 设  $(X, Y)$  为连续型随机向量, 在  $Y = y$  的条件下  $X$  的条件密度函数为  $f_{X|Y}(x|y)$ , 称

$$\mathbb{E}(X|y) = \mathbb{E}(X|Y = y) = \int_{-\infty}^{+\infty} x f_{X|Y}(x|y) dx$$

为在  $Y = y$  的条件下  $X$  的**条件期望**.

无条件期望  $\mathbb{E}(X)$  是一个常数, 而条件期望  $\mathbb{E}(X|Y = y)$  是  $y$  的函数; 例如用  $X$  表示中国成年人的身高,  $Y$  表示中国成年人的足长, 我国公安部门研究得足长为  $y$  的中国成年人平均身高为  $\mathbb{E}(X|Y = y) = 6.876y$ , 此公式常用于公安痕迹侦查中.

## 条件期望的性质

- **线性性.** 对任意常数  $a, b$  有  $\mathbb{E}(aX_1 + bX_2|Y) = a\mathbb{E}(X_1|Y) + b\mathbb{E}(X_2|Y)$ ;
- **函数型.** 对离散型随机向量  $(X, Y)$  和函数  $g(X)$ , 有

$$\mathbb{E}(g(X)|Y) = \sum_i g(x_i)P(X = x_i|Y = y)$$

对连续型随机向量  $(X, Y)$  和函数  $g(X)$ , 有

$$\mathbb{E}(g(X)|Y) = \int_{-\infty}^{+\infty} g(x)f(x|Y = y)dx$$

- 若随机向量  $(X, Y) \sim \mathcal{N}(\mu_x, \mu_y, \sigma_x^2, \sigma_y^2, \rho)$ , 则在  $Y = y$  的条件下随机变量  $X$  服从正态分布  $\mathcal{N}(\mu_x - \rho\sigma_x(y - \mu_y)/\sigma_y, (1 - \rho^2)\sigma_x^2)$ , 由此可得

$$\mathbb{E}(X|y) = \mu_x - \frac{\rho\sigma_x(y - \mu_y)}{\sigma_y}$$

## 多维随机向量函数的条件期望：例 0.98

例 0.98 设随机向量  $(X, Y)$  的联合概率密度为

$$f(x, y) = \begin{cases} \exp(-y), & 0 < x < y < +\infty \\ 0, & \text{其它} \end{cases}$$

求条件期望  $\mathbb{E}(X|y)$ .

## 解答：例 0.98

题目：如上所述.

解答：

- 根据条件期望的定义  $\mathbb{E}(X|y) = \int_{-\infty}^{+\infty} x f_{X|Y}(x|y) dx$ , 计算  $Y$  的边缘密度函数, 当  $y > 0$  时

$$f_Y(y) = \int_{-\infty}^{+\infty} f(x, y) dx = \int_0^y \exp(-y) dx = y \exp(-y),$$

由此得到条件分布

$$f_{X|Y}(x|y) = \frac{f(x, y)}{f_Y(y)} = \frac{1}{y} \quad (0 < x < y < +\infty),$$

由此可得

$$\mathbb{E}(X|y) = \int_{-\infty}^{+\infty} x f_{X|Y}(x|y) dx = \int_0^y \frac{x}{y} dx = \frac{y}{2}.$$

## 二重期望公式

**定理 0.30** [二重期望公式] 设  $(X, Y)$  是二维随机向量, 且  $\mathbb{E}(X)$  存在, 则

$$\begin{aligned}\mathbb{E}(X) &= \mathbb{E}(\mathbb{E}(X|Y)) \\ &= \begin{cases} \sum_i \mathbb{E}(X|Y = y_i)P(Y = y_i), & \text{若 } Y \text{ 是一个离散型随机变量} \\ \int_{-\infty}^{+\infty} \mathbb{E}(X|Y = y)f_Y(y) dy, & \text{若 } Y \text{ 是一个连续型随机变量} \end{cases}\end{aligned}$$

二重期望公式在实际中很有用, 譬如, 在计算取值范围很大的  $X$  的期望  $\mathbb{E}(X)$  时, 可以通过构建与  $X$  有关的量  $Y$ , 通过  $Y$  的不同取值将大范围划分成若干小区域. 先在小区域上求  $X$  的平均, 再对此类平均求加权平均, 即可得到大范围上  $X$  的期望  $\mathbb{E}(X)$ .

## 推论：全期望公式

回顾: 对任意事件  $A$  而言, 根据全概率公式有  $P(A) = \sum_{i=1}^n P(B_i)P(A|B_i)$ ; 即通过对样本空间的切割划分, 将一个复杂事件化成相对简单的事件来求其概率; 借鉴这种化繁为简的思想, 也可以通过全期望公式计算复杂事件的期望, 具体如下:

**定理 0.31** 设  $A_1, A_2, \dots, A_n$  是样本空间  $\Omega$  一个分割,  $A_i A_j = \emptyset$  和  $\Omega = \bigcup_{i=1}^n A_i$ . 对任意随机变量  $X$  有

$$\mathbb{E}(X) = \mathbb{E}(X|A_1)P(A_1) + \mathbb{E}(X|A_2)P(A_2) + \cdots + \mathbb{E}(X|A_n)P(A_n),$$

特别的, 随机事件  $A$  及其对立事件  $\bar{A}$  构成空间  $\Omega$  一个分割, 对任意随机变量  $X$  有

$$\mathbb{E}(X) = \mathbb{E}(X|A)P(A) + \mathbb{E}(X|\bar{A})P(\bar{A}).$$

可证.

## 多维随机向量函数的条件期望：例 0.99

**例 0.99** 一矿工被困在有三个门的矿井里, 第一个门通一坑道, 沿此坑道走 3 小时可使他到达安全地点; 第二个门可使他走 5 小时后回到原处; 第三个门可使他走 7 小时后也回到原地. 如设此矿工在任何时刻都等可能地选定其中一个门, 试问他到达安全地点平均要用多长时间?



## 解答：例 0.99

题目：如上所述.

解答：

- 设  $X$  为该矿工回到安全地点所需的时间, 易知  $X$  的取值为

$$3, 5 + 3, 7 + 3, 5 + 5 + 3, 5 + 7 + 3, 7 + 7 + 3, \dots$$

直接计算取值范围很大的  $X$  的期望  $\mathbb{E}(X)$  较困难, 因此构建变量  $Y$  表示该矿工第一次选择的门的序号. 因此

$$P(Y = 1) = P(Y = 2) = P(Y = 3) = \frac{1}{3},$$

- 若矿工选择第一个门, 则  $\mathbb{E}(X|Y = 1) = 3$ ; 若矿工选择第二个门, 则  $\mathbb{E}(X|Y = 2) = 5 + \mathbb{E}(X)$ ; 若矿工选择第三个门, 则  $\mathbb{E}(X|Y = 3) = 7 + \mathbb{E}(X)$ ; 综上所述, 由定理0.30有

$$\mathbb{E}(X) = \frac{1}{3}[3 + 5 + \mathbb{E}(X) + 7 + \mathbb{E}(X)] = 5 + \frac{2}{3}\mathbb{E}(X),$$

由此可得  $\mathbb{E}(X) = 15$ .

## 多维随机向量函数的协方差

**定义 0.56** 设二维随机向量  $(X, Y)$  的期望  $\mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])]$  存在, 则称其为  $X$  与  $Y$  的协方差, 记为

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y].$$

从协方差的定义可以看出, 它是  $X$  的偏差“ $X - \mathbb{E}[X]$ ”与  $Y$  的偏差“ $Y - \mathbb{E}[Y]$ ”乘积的数学期望, 由于偏差可正可负, 故协方差也可正可负, 也可为零.

# 协方差的性质

- 对任意随机变量  $X$  与  $Y$ , 有

$$\text{Cov}(X, X) = 0 \quad \text{和} \quad \text{VAR}(X \pm Y) = \text{VAR}(X) + \text{VAR}(Y) \pm 2\text{Cov}(X, Y)$$

- 对任意随机变量  $X$  与  $Y$  和常数  $c$ , 有

$$\text{Cov}(X, c) = 0 \quad \text{和} \quad \text{Cov}(X, Y) = \text{Cov}(Y, X)$$

- 对任意随机变量  $X_1$ 、 $X_2$  和  $Y$ , 有

$$\text{Cov}(X_1 + X_2, Y) = \text{Cov}(X_1, Y) + \text{Cov}(X_2, Y)$$

- 若随机变量  $X$  与  $Y$  相互独立, 则有  $\text{Cov}(X, Y) = 0$ , 但反之不成立;
- 对任意随机变量  $X$  与  $Y$  有

$$(\text{Cov}(X, Y))^2 \leq \text{VAR}(X) \cdot \text{VAR}(Y)$$

等号成立的充要条件是  $Y = aX + b$  几乎处处成立, 即  $X$  与  $Y$  之间几乎处处存在线性关系. (可证)

## 多维随机向量函数的协方差：例 0.100

例 0.100 设随机变量  $(X, Y)$  的联合概率密度为

$$f(x, y) = \begin{cases} (x, y)/8, & 0 \leq x \leq 2, 0 \leq y \leq 2 \\ 0, & \text{其它} \end{cases}$$

求协方差  $\text{Cov}(X, Y)$  和方差  $\sigma(X + Y)$ .

## 解答：例 0.100

题目：如上所述.

解答：

- 根据协方差的定义  $\text{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]$ , 计算

$$\mathbb{E}[X] = \mathbb{E}[Y] = \int_0^2 \int_0^2 \frac{x(x+y)}{8} dx dy = \frac{7}{6}, \quad \mathbb{E}[XY] = \int_0^2 \int_0^2 \frac{xu(x+y)}{8} dx dy = \frac{4}{3}$$

由此可得  $\text{Cov}(X, Y) = -1/36$ .

- 根据方差的定义  $\sigma(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$ , 计算

$$\mathbb{E}[X^2] = \mathbb{E}[Y^2] = \int_0^2 \int_0^2 x^2(x+y)/8 dx dy = 5/3$$

得  $\sigma(X) = \sigma(Y) = 11/36$ . 最后得到

$$\sigma(X + Y) = \sigma(X) + \sigma(Y) + 2\text{Cov}(X, Y) = 5/9.$$

## 多维随机向量函数的协方差：例 0.101

**例 0.101** 有  $n$  对夫妻参加一次聚会, 将所有参会人员任意分成  $n$  组, 每组一男一女, 用  $X$  表示夫妻两人被分到一组的对数, 求  $X$  的期望和方差.

## 解答：例 0.101

题目：有  $n$  对夫妻参加一次聚会，将所有参会人员任意分成  $n$  组，每组一男一女，用  $X$  表示夫妻两人被分到一组的对数，求  $X$  的期望和方差.

解答：

- 用  $X_i$  表示第  $i$  对夫妻是否被分到一组，即

$$X_i = \begin{cases} 1, & \text{第 } i \text{ 对夫妻被分到一组} \\ 0, & \text{否则} \end{cases}$$

则  $X = X_1, X_2, \dots, X_n$ . 随机变量  $X_i$  得分布列为

$$P(X_i = 1) = (n-1)!/n! = 1/n, \quad \text{和} \quad P(X_i = 0) = 1 - 1/n$$

于是得到期望

$$\mathbb{E}[X] = \mathbb{E}(X_1, X_2, \dots, X_n) = \mathbb{E}(X_1) + \mathbb{E}(X_2) + \dots + \mathbb{E}(X_n) = 1.$$

- 对任意  $i \neq j$ , 有

$$P(X_i = 1, X_j = 1) = (n-2)!/n! = 1/n(n-1),$$

由此得到

$$\text{Cov}(X_i, X_j) = \mathbb{E}[X_i X_j] - \mathbb{E}[X_i]\mathbb{E}[X_j] = 1/n^2(n-1),$$

最后根据协方差的性质有

$$\sigma(X) = \sum_{i=1}^n \sigma(X_i) + 2 \sum_{i \neq j} \text{Cov}(X_i, X_j) = 1.$$



## 插播：线性运算的基本性质

- 回忆：矩阵的特征值和特征向量. 以二维为例, 矩阵  $\mathbf{A}$  拥有特征值  $\Lambda_1$  和  $\Lambda_2$ , 分别对应特征向量  $\mathbf{u}_1, \mathbf{u}_2$ . 则有

$$\mathbf{A}\mathbf{u}_i = \Lambda_i\mathbf{u}_i, \quad i = 1, 2$$

进而有  $\mathbf{A} = \mathbf{U}^\top \mathbf{\Lambda} \mathbf{U}$  with  $\mathbf{U}^\top = \mathbf{U}^{-1}$ , 即

$$\begin{pmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{pmatrix} = \begin{pmatrix} u_{11} & u_{21} \\ u_{12} & u_{22} \end{pmatrix} \begin{pmatrix} \Lambda_1 & 0 \\ 0 & \Lambda_2 \end{pmatrix} \begin{pmatrix} u_{11} & u_{12} \\ u_{21} & u_{22} \end{pmatrix}$$

- 几何性质. For the case of  $\mathbf{A}\mathbf{v}$  given any  $\mathbf{v}$ ,
  - 矩阵  $\mathbf{U}$  负责对  $\mathbf{v}$  进行旋转
  - 矩阵  $\mathbf{\Lambda}$  负责对  $\mathbf{v}$  进行放缩

## 插播：线性运算的基本性质

如果我们面对一个运算  $\mathbf{A}\mathbf{x} + \mathbf{b}$ ,

- $\mathbf{b}$  是平移
- $\mathbf{U}$  是旋转
- $\mathbf{\Lambda}$  是放缩

# 协方差与方差

- 方差. 衡量单变量自身的波动性或者偏离性.

$$\text{VAR}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2]$$

- 协方差. 衡量变量间的偏离性

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y].$$

- 可以定义矩阵  $\Sigma$  用以衡量多变量的偏离程度

$$\Sigma = \begin{pmatrix} \text{VAR}(X) & \text{Cov}(X, Y) \\ \text{Cov}(X, Y) & \text{VAR}(Y) \end{pmatrix}$$

## 二维正态分布的协方差

**定理 0.32** 若随机向量  $(X, Y) \sim \mathcal{N}(\mu_x, \mu_y, \sigma_x^2, \sigma_y^2, \rho)$ , 则

$$\text{Cov}(X, Y) = \rho \sigma_x \sigma_y$$

**推论** 若随机向量  $(X, Y) \sim \mathcal{N}(\mu_x, \mu_y, \sigma_x^2, \sigma_y^2, \rho)$ , 则  $X$  与  $Y$  相互独立的充要条件是  $\text{Cov}(X, Y) = 0$ .

可证.

# 随机向量的数学期望与协方差阵

$n$  维随机向量的数学期望及方差可以通过矩阵形式给出.

**定义 0.57** 设  $n$  维随机向量为  $\mathbf{X} = (X_1, X_2, \dots, X_n)'$ , 若每个分量的数学期望都存在, 则称

$$\mathbb{E}[\mathbf{X}] = (\mathbb{E}[X_1], \mathbb{E}[X_2], \dots, \mathbb{E}[X_n])',$$

为  $\mathbf{X}$  的数学期望向量, 简称  $\mathbf{X}$  的数学期望. 而称

$$\begin{aligned} & \mathbb{E}[(\mathbf{X} - \mathbb{E}[\mathbf{X}])(\mathbf{X} - \mathbb{E}[\mathbf{X}])'] \\ &= \begin{bmatrix} \sigma_{X_1} & \text{Cov}(X_1, X_2) & \cdots & \text{Cov}(X_1, X_n) \\ \text{Cov}(X_2, X_1) & \sigma_{X_2} & \cdots & \text{Cov}(X_2, X_n) \\ \vdots & \vdots & & \vdots \\ \text{Cov}(X_n, X_1) & \text{Cov}(X_n, X_2) & \cdots & \sigma_{X_n} \end{bmatrix} \end{aligned}$$

为  $\mathbf{X}$  的方差-协方差矩阵, 简称  $\mathbf{X}$  的协方差阵.

## 随机向量的协方差阵的性质

通过定义 0.57 可以看到  $n$  维随机向量的各分量的方差构成了协方差阵对角线上的元素, 非对角线的元素为协方差.

**定理 0.33**  $n$  维随机向量的协方差阵  $\text{Cov}(\mathbf{X}) = (\text{Cov}(X_i, X_j))_{n \times n}$  是一个对称的非负定矩阵.

## 多维随机向量函数的协方差：例 0.102

**例 0.102** 设随机变量  $X_1, X_2, \dots, X_n$  相互独立且服从正态分布, 方差为  $\sigma^2$ . 记  $\bar{X} = \sum_{i=1}^n X_i/n$ , 讨论  $\bar{X}$  和  $\bar{X} - X_i$  的独立性.

## 解答：例 0.102

题目：设随机变量  $X_1, X_2, \dots, X_n$  相互独立且服从正态分布，方差为  $\sigma^2$ 。记  $\bar{X} = \sum_{i=1}^n X_i/n$ ，讨论  $\bar{X}$  和  $\bar{X} - X_i$  的独立性。

解答：

- 根据正态分布的性质易知  $\bar{X}$  和  $\bar{X} - X_i$  都服从正态分布，根据定理0.32可知正态分布的独立性可通过协方差来研究。根据协方差的性质有

$$\text{Cov}(\bar{X}, \bar{X} - X_i) = \text{Cov}(\bar{X}, \bar{X}) - \text{Cov}(\bar{X}, X_i) = \sigma(\bar{X}) - \text{Cov}\left(\sum_{j=1}^n \frac{X_j}{n}, X_i\right)$$

- 根据  $X_1, X_2, \dots, X_n$  相互独立有

$$\sigma(\bar{X}) = \frac{1}{n^2} \sigma \left( \sum_{i=1}^n X_i \right) = \frac{\sigma^2}{n} \quad \text{和} \quad \text{Cov}\left(\sum_{j=1}^n \frac{X_j}{n}, X_i\right) = \frac{1}{n} \text{Cov}(X_i, X_i) = \frac{\sigma^2}{n}$$

于是得到  $\text{Cov}(\bar{X}, \bar{X} - X_i) = 0$ ，根据定理0.32的推论可知  $\bar{X}$  和  $\bar{X} - X_i$  相互独立。



## 多维随机向量函数的相关系数

两个随机变量之间的关系可以分为独立与非独立, 其中非独立关系中又可以分为线性关系和非线性关系, 线性相关程度通过线性相关系数来定义.

**定义 0.58** 设  $(X, Y)$  为二维随机向量, 如果它们的方差  $\sigma_X$  和  $\sigma_Y$  存在且都不为零, 则称

$$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sqrt{\sigma_X \sigma_Y}}.$$

为  $X$  与  $Y$  的线性相关系数, 简称相关系数.

## 相关系数的性质

- 对任意随机变量  $X$  与  $Y$ , 有  $|\rho_{XY}| \leq 1$ . 等号成立的充要条件是  $Y = aX + b$  几乎处处成立, 即  $X$  与  $Y$  之间几乎处处存在线性关系.
  - 若  $\rho_{XY} = 0$ , 称  $X$  与  $Y$  **不相关**. 不相关是指  $X$  与  $Y$  之间没有线性关系, 但  $X$  与  $Y$  之间可能存在其他的函数关系, 比如平方关系、对数关系等;
  - 若  $\rho_{XY} = 1$ , 称  $X$  与  $Y$  **完全正相关**; 若  $\rho_{XY} = -1$ , 称  $X$  与  $Y$  **完全负相关**;
  - 若  $0 < |\rho_{XY}| < 1$ , 称  $X$  与  $Y$  **“有一定程度”的线性关系**; 若  $|\rho_{XY}|$  越接近于 1, 则线性相关程度越高; 若  $|\rho_{XY}|$  越接近于 0, 则线性相关程度越低.
- 若随机变量  $X$  与  $Y$  相互独立, 则  $X$  与  $Y$  不相关, 但反之不成立.

## 正态分布的相关系数

**定理 0.34** 若随机向量  $(X, Y) \sim \mathcal{N}(\mu_x, \mu_y, \sigma_x^2, \sigma_y^2, \rho)$ , 则  $X$  与  $Y$  的线性相关系数  $\rho_{XY} = \rho$ , 以及  $X$  与  $Y$  相互独立充要条件是  $X$  与  $Y$  不相关.

独立与不相关的等价性仅限于正态分布随机变量, 对于其他类型不一定成立.

## 不相关的等价条件

**定理 0.35** 若随机变量  $X$  与  $Y$  的方差存在且都不为零, 以下几个条件相互等价:

- $X$  与  $Y$  不相关, 即  $\rho_{XY} = 0$ ;
- 协方差  $\text{Cov}(X, Y) = 0$ ;
- $\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$ ;
- $\sigma(X \pm Y) = \sigma(X) + \sigma(Y)$ .

## 多维随机向量函数的相关系数：例 0.103

**例 0.103** 设随机变量  $X \sim \mathcal{N}(\mu, \sigma^2)$  和  $Y \sim \mathcal{N}(\mu, \sigma^2)$  相互独立, 求  $Z_1 = \alpha X + \beta Y$  和  $Z_2 = \alpha X - \beta Y$  的相关系数 ( $\alpha, \beta \neq 1$ ).

## 解答：例 0.103

题目：设随机变量  $X \sim \mathcal{N}(\mu, \sigma^2)$  和  $Y \sim \mathcal{N}(\mu, \sigma^2)$  相互独立, 求  $Z_1 = \alpha X + \beta Y$  和  $Z_2 = \alpha X - \beta Y$  的相关系数 ( $\alpha, \beta \neq 1$ ).

解答:

- 根据相关系数的定义  $\rho_{Z_1 Z_2} = \frac{\text{Cov}(Z_1, Z_2)}{\sqrt{\sigma_{Z_1} \sigma_{Z_2}}}$ , 计算

$$\text{Cov}(Z_1, Z_2) = \text{Cov}(\alpha X + \beta Y, \alpha X - \beta Y) = (\alpha^2 - \beta^2)\sigma^2$$

$$\sigma_{Z_1} = \text{Cov}(\alpha X + \beta Y, \alpha X + \beta Y) = (\alpha^2 + \beta^2)\sigma^2$$

$$\sigma_{Z_2} = \text{Cov}(\alpha X - \beta Y, \alpha X - \beta Y) = (\alpha^2 + \beta^2)\sigma^2$$

由此可得  $\rho_{Z_1 Z_2} = (\alpha^2 - \beta^2)/(\alpha^2 + \beta^2)$ .

## 多维随机向量函数的相关系数：例 0.104

**例 0.104** 设随机向量  $(X_1, X_2, \dots, X_n)$  服从多项分布  $M(m, p_1, p_2, \dots, p_n)$ , 对任意  $i \neq j$ , 求  $X_i$  和  $X_j$  的相关系数.

## 解答：例 0.104

题目：设随机向量  $(X_1, X_2, \dots, X_n)$  服从多项分布  $M(m, p_1, p_2, \dots, p_n)$ , 对任意  $i \neq j$ , 求  $X_i$  和  $X_j$  的相关系数.

解答：

- 根据多项分布的性质有

$$X_i \sim B(m, p_i) \quad \text{和} \quad X_j \sim B(m, p_j)$$

由此可得  $\sigma(X_i) = mp_i(1 - p_i)$  和  $\sigma(X_j) = mp_j(1 - p_j)$ .

- 对每个  $k \in [m]$ , 引入随机变量

$$Y_i^k = \begin{cases} 1, & \text{若第 } k \text{ 次实验的结果为 } i \\ 0, & \text{其它} \end{cases} \quad \text{和} \quad Y_j^k = \begin{cases} 1, & \text{若第 } k \text{ 次实验的结果为 } j \\ 0, & \text{其它} \end{cases}$$

由此可得

$$X_i = Y_i^1 + Y_i^2 + \dots + Y_i^m \quad \text{和} \quad X_j = Y_j^1 + Y_j^2 + \dots + Y_j^m$$



- 根据第  $k$  次实验和第  $l$  次实验相互独立 ( $k \neq l$ ), 以及  $Y_i^k Y_j^k = 0$  有

$$\text{Cov}(Y_i^k, Y_j^l) = 0 \quad \text{和} \quad \text{Cov}(Y_i^k, Y_j^k) = \mathbb{E}[Y_i^k Y_j^k] - \mathbb{E}[Y_i^k] \mathbb{E}[Y_j^k] = -p_i p_j$$

根据协方差的性质有

$$\text{Cov}(X_i, X_j) = \sum_{k=1}^m \text{Cov}(Y_i^k, Y_j^k) + \sum_{k \neq l} \text{Cov}(Y_i^k, Y_j^l) = -m p_i p_j$$

由此可得  $X_i$  和  $X_j$  的相关系数

$$\rho = \frac{\text{Cov}(X_i, X_j)}{\sigma(X_i)\sigma(X_j)} = \frac{-m p_i p_j}{\sqrt{m p_i (1 - p_i)} \sqrt{m p_j (1 - p_j)}} = -\frac{p_i p_j}{\sqrt{p_i (1 - p_i)} \sqrt{p_j (1 - p_j)}}$$